

**UNIVERSIDAD POLITÉCNICA DE MADRID
ESCUELA TÉCNICA SUPERIOR DE INGENIEROS DE
TELECOMUNICACIÓN**

**UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE CIENCIAS MATEMÁTICAS**

**MÁSTER EN TRATAMIENTO ESTADÍSTICO COMPUTACIONAL DE
LA INFORMACIÓN**



TRABAJO DE FIN DE MÁSTER

**Análisis de campimetrías visuales: modelos de interpolación espacial
y clasificación de defectos en el campo visual**

Ágata De Isidro Navarro

**Director: Carlos Gregorio Rodríguez
Directora: M. Mar Fenoy Muñoz**

Madrid, 2021

Resumen

Las campimetrías ópticas constituyen uno de los recursos fundamentales empleados por los oftalmólogos para el diagnóstico de multitud de afecciones oculares como el glaucoma u otras enfermedades neurooftalmológicas. Por ello, extraer el máximo posible de información de estas pruebas diagnósticas es una cuestión de importancia, pues implicaría el diagnóstico precoz de estas enfermedades. Estas pruebas sintetizan la información del estado del campo visual de un paciente en una matriz de números. Este trabajo, mediante el ajuste de distintos modelos de interpolación espacial, pretende ampliar esa información a lo largo del campo visual y así, ayudar a que se tomen mejores decisiones clínicas. Por otro lado, existen diversos defectos visuales tipificados asociados a diversas enfermedades y problemas oculares. Mediante una segmentación de pacientes, se agrupará un conjunto de campimetrías en distintas categorías ligadas a estos defectos típicos, a fin de facilitar el diagnóstico del paciente que se está tratando.

Palabras-clave: campimetría, defecto visual, glaucoma, *clustering*, interpolación espacial, geoestadística

Abstract

The visual field tests are one of the main resources used by ophthalmologist for the diagnosis of a bunch of eye conditions, among which stands out the glaucoma and other neuro-ophthalmological diseases. Therefore, the correct use of the information stored in them is crucial for the early diagnosis of these diseases. These tests synthesize information on the status of a patient's visual field in a matrix of numbers. This work, by adjusting different spatial interpolation models, aims to expand that information throughout the visual field and thus help better clinical decisions be made. In addition, there are various typified visual defects associated with various eye diseases and problems. Through patient segmentation, a set of campimetries will be grouped into different categories linked to these typical defects, in order to facilitate the diagnosis of the patient being treated.

Key-words: campimetry, visual defect, glaucoma, clustering, spatial interpolation, geostatistics

Yo, **Ágata De Isidro Navarro**, alumna del Máster en Tratamiento Estadístico Computacional de la Información de la Universidad Politécnica y Complutense de Madrid, con correo agata.deisidro.navarro@alumnos.upm.es y agatadei@ucm.es autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Máster en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Asimismo, el código fuente del proyecto y esta documentación pueden consultarse en la dirección https://github.com/Agaisina/TFM_2021, para que aquellos que lo deseen puedan conocer el proyecto.

Fdo: Ágata De Isidro Navarro

Madrid a 7 de febrero de 2021

Índice general

1. Introducción	1
1.1. El campo visual	1
1.2. Motivación	4
1.3. Objetivos	5
2. Metodología	6
2.1. Presentación de los datos	7
2.1.1. Ubicación de los puntos de medición: Patrón G	7
2.1.2. Variable de estudio	9
2.2. Análisis descriptivo	10
2.3. Técnicas interpolativas espaciales	12
2.3.1. Métodos de interpolación no geoestadísticos: Inverse Distance Weighted Interpolation (IDW)	12
2.3.2. Métodos de interpolación geoestadísticos: Kriging	12
2.3.3. Estratificación del área de estudio	13
2.4. Evaluación de la bondad de ajuste de los modelos de interpolación	13
3. Segmentación de pacientes	15
3.1. Zonificación del campo visual y sus defectos típicos	15
3.2. Segmentación de pacientes: clustering	18
3.2.1. Variables: índices globales	18
3.2.2. Determinación del número óptimo de clústers	19
3.3. Resultados	19
3.3.1. Resultado de las segmentaciones de pacientes	20
3.3.2. Ejemplos de predicción de campimetrías	26
4. Modelos interpolativos	30
4.1. IDW global	30
4.2. IDW estratificado	33
4.2.1. Zonificación en 8 sectores	33
4.2.2. Zonificación en 10 sectores	34
4.3. Kriging global	35
4.4. Kriging global por clústeres	38
4.4.1. Segmentación 1	38
4.4.2. Segmentación 2	40
4.5. Comparación entre modelos	42
4.5.1. Ejemplo de los modelos	43

5. Conclusiones y trabajo futuro	45
A. Campos de los datos	
B. Medidas de error en el modelo de kriging global por clústers	
B.1. Segmentación 1	
B.2. Segmentación 2	
Bibliografía	

Índice de figuras

1.1. Prodecimiento de realización de una prueba perimétrica. Extraído de [17]	1
1.2. Perimetria ideal vs práctica. Extraído de [17]	2
1.3. Ejemplo del resultado de una campimetría realizada con un perímetro <i>Octopus</i>	3
1.4. Simulación de la pérdida de visión asociada a los resultados de sus pruebas correspondientes. Extraído de [4]	3
2.1. Esquema del trabajo	6
2.2. Patrón G. Extraído de [17]	8
2.3. Metodología de agrupación del patrón G en el <i>análisis clúster</i> . Extraído de [17]	8
2.4. Distribución del defecto visual en los puntos de los conjuntos de muestra	10
2.5. Distribución del defecto medio por campimetría de los conjuntos de muestra	11
3.1. Zonificación del campo visual	16
3.2. Defectos típicos del campo visual. Figuras extraídas de [17]	16
3.3. Defectos típicos del campo visual: Pérdida total de visión. Extraído de [11]	17
3.4. Distancia euclídea entre centroides	21
3.5. Método del codo, <i>Gap Statistic</i> y Método de la silueta	22
3.6. Segmentación 1	23
3.7. Segmentación 2	24
3.8. Segmentación 1: Predicción de campimetrías (i)	26
3.9. Segmentación 1: Predicción de campimetrías (ii)	27
3.10. Segmentación 2: Predicción de campimetrías (i)	28
3.11. Segmentación 2: Predicción de campimetrías (ii)	29
4.1. Evolución de las medidas de error con respecto al número de vecinos. IDW	31
4.2. Distribución de las medidas de error. IDW	32
4.3. Distribución de las medidas de error. IDW estratificado 8 sectores	33
4.4. Distribución de las medidas de error. IDW estratificado 10 sectores	34
4.5. Semivariograma de medias ajustado a distintos modelos	35
4.6. Distribución de las medidas de error. Kriging Global	37
4.7. Distribución de las medidas de error. Kriging global: Segmentación 1	39
4.8. Distribución de las medidas de error. Kriging global: Segmentación 2	41
4.9. Defecto normalizado en la campimetría de ejemplo	43
4.10. Ejemplo de interpolación de la campimetría de ejemplo utilizando los diferentes modelos	44

B.1.	Evolución de las medidas de error por número de vecinos. Segmentación 1 (i)
B.2.	Evolución de las medidas de error por número de vecinos. Segmentación 1 (ii)
B.3.	Evolución de las medidas de error por número de vecinos. Segmentación 1 (iii)
B.4.	Evolución de las medidas de error por número de vecinos. Segmentación 1 (iv)
B.5.	Evolución de las medidas de error por número de vecinos. Segmentación 1 (v)
B.6.	Medidas de error por modelos, fijado n. Segmentación 1 (i)
B.7.	Medidas de error por modelos, fijado n. Segmentación 1 (ii)
B.8.	Evolución de las medidas de error por número de vecinos. Segmentación 2 (i)
B.9.	Evolución de las medidas de error por número de vecinos. Segmentación 2 (ii)
B.10.	Evolución de las medidas de error por número de vecinos. Segmentación 2 (iii)
B.11.	Evolución de las medidas de error por número de vecinos. Segmentación 2 (iv)
B.12.	Medidas de error por modelos, fijado n. Segmentación 2 (i)
B.13.	Medidas de error por modelos, fijado n. Segmentación 2 (ii)

Índice de tablas

2.1. Resultados de la campimetría	9
3.1. Tamaño de los clústeres	20
3.2. Medidas del clustering en la segmentación 1	21
3.3. Medidas del clustering en la segmentación 2	21
3.4. Equiparación de los clústeres a su defecto visual (Segmentación 1)	23
3.5. Equiparación de los clústeres a su defecto visual (Segmentación 1)	24
3.6. Correspondencias entre clústeres de las dos segmentaciones	25
4.1. IDW Global: media de errores sobre el conjunto de Validación	31
4.2. IDW Global: media de errores sobre el conjunto de Test	32
4.3. Kriging global: media de errores sobre el conjunto de Validación	36
4.4. Kriging global: media de errores sobre el conjunto de Test	36
4.5. Segmentación 1: Modelos seleccionados	38
4.6. Kriging global por clústeres - Segmentación 1: Media de errores en el conjunto de Test	39
4.7. Segmentación 2: Modelos seleccionados	40
4.8. Kriging global por clústeres - Segmentación 2: Media de errores en el conjunto de Test	40
4.9. Media de errores del conjunto de Test para todos los modelos	42
A.1. Campos información paciente. Información extraída de [5]	
A.2. Campos resultados prueba en cada punto de la campimetría. Información extraída de [5]	
A.3. Campos información prueba. Información extraída de [5]	

Capítulo 1

Introducción

1.1. El campo visual

El campo visual de una persona se define como el área en que una persona puede ver en un momento dado en relación con una dirección fijada, es decir, define los límites del área más allá de la cual no se puede ver nada. La extensión del campo visual no es suficiente para describir la visión de una persona; también es importante tener una medida de la sensibilidad a la luz. Esta sensibilidad no se distribuye uniformemente en la extensión espacial del campo visual y depende de la ubicación dentro del mismo. [17]

La prueba diagnóstica que se encarga de medir dicha sensibilidad a la luz se denomina perimetría o campimetría; la cual tiene por objetivo examinar las alteraciones del campo visual del paciente. Este tipo de prueba en concreto se basa en mediciones sistemáticas de la sensibilidad a la luz. Para realizar una prueba perimétrica, se pide a los pacientes que se sienten frente al equipo de trabajo con la cabeza estabilizada, manteniendo la visión fija en el centro. Una vez situado el paciente, se le somete a distintos estímulos lumínicos a lo largo de su campo visual y el mismo deberá indicar, mediante un pulsador, cuándo es capaz de percibir la luz. [17]

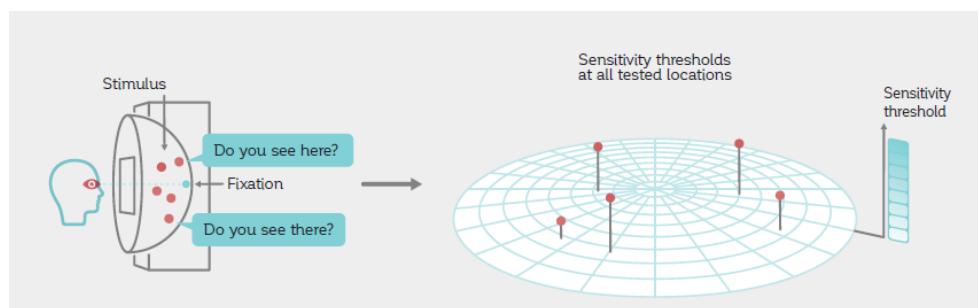


Figura 1.1: Procedimiento de realización de una prueba perimétrica. Extraído de [17]

Una persona puede experimentar pérdida del campo visual cuando se daña la retina, el nervio óptico o las partes visuales del cerebro, incluido el lóbulo occipital. Las causas más comunes de daño a la retina o al nervio óptico del ojo incluyen glaucoma (una enfermedad ocular que provoca la pérdida progresiva de fibras nerviosas del ner-

vio óptico), coloboma, una infección por toxoplasma, tumores y degeneración macular relacionada con la edad y otras enfermedades neurooftalmológicas [3]

La realización de campimetrías es fundamental para la detección y seguimiento de las enfermedades y condiciones citadas anteriormente. Las pérdidas de visión causadas por estas enfermedades son permanentes e irreversibles, pero el correcto estudio de la información aportada por estas pruebas permitirá realizar los tratamientos pertinentes para la mejor evolución de las mismas.

Idealmente, una perimetría proporcionaría la sensibilidad a la luz del paciente en una escala continua de intensidades luminosas, además de proporcionar este valor en todos los puntos del campo visual. Desde un punto de vista práctico, esto es imposible de realizar. Por esta razón, en las perimetrías, los estímulos se miden en un número fijo de ubicaciones clave y en un número limitado de niveles de intensidad luminosa [17]

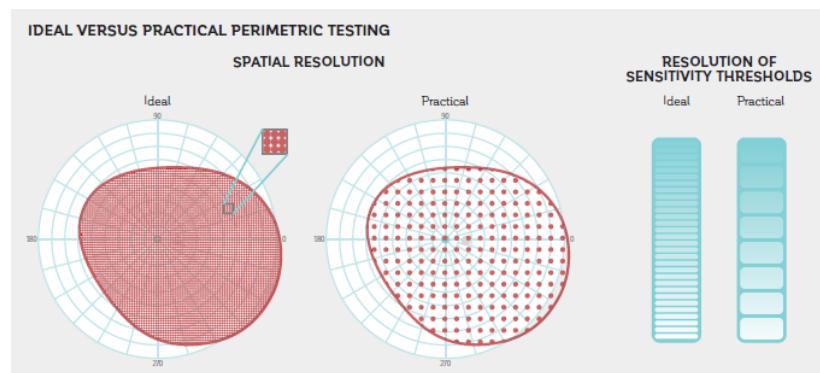


Figura 1.2: Perimetria ideal vs práctica. Extraído de [17]

Este enfoque introduce inexactitudes en la prueba perimétrica, por lo que la elección de los patrones de medición debe ser un compromiso entre la duración de la prueba y la precisión de la misma, garantizando que la información extraída sea suficiente para tomar las decisiones clínicas oportunas. Existen numerosos tipos de prueba que dependen de parámetros como el color de fondo y su luminancia, el estímulo máximo que se mide, así como su duración [17]. La elección de estos parámetros, así como la ubicación de los puntos de medida, dependerá de la patología que se esté estudiando.

Con mucha frecuencia se utilizan campimetrías, que son pruebas perimétricas de los primeros 30°. En suma, una prueba perimétrica o una campimetría traslada la información de la sensibilidad visual de un paciente y con ello, su estado de visión, a una matriz de números. A continuación se muestra el resultado de una campimetría realizada con el perímetro *Octopus*, para ejemplificar la información que se obtiene de ésta.

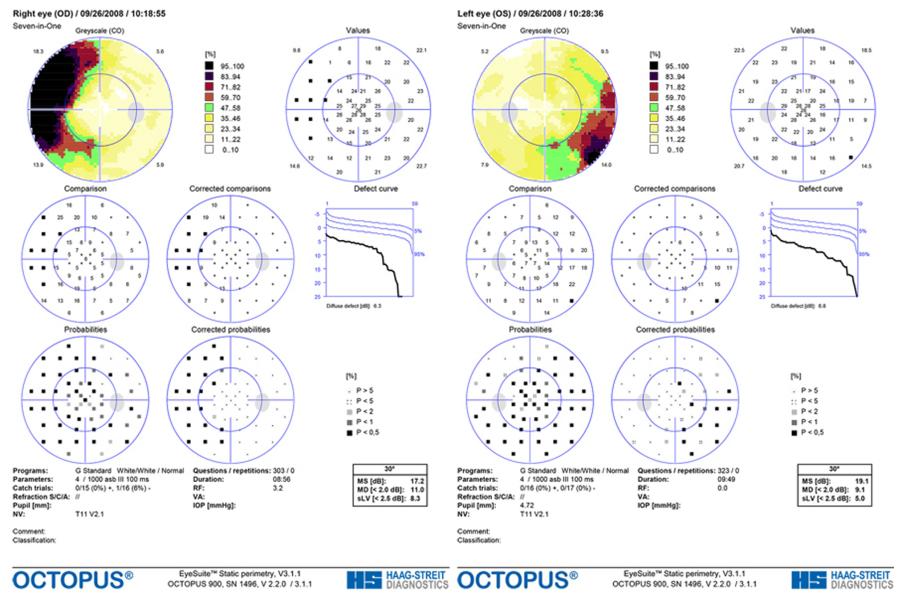


Figura 1.3: Ejemplo del resultado de una campimetria realizada con un perímetro *Octopus*

Para terminar, la figura figura 1.4, donde se reflejan mediante una simulación, las pérdidas de visión recogidas en sus campimetrías correspondientes (a la derecha de la imagen)

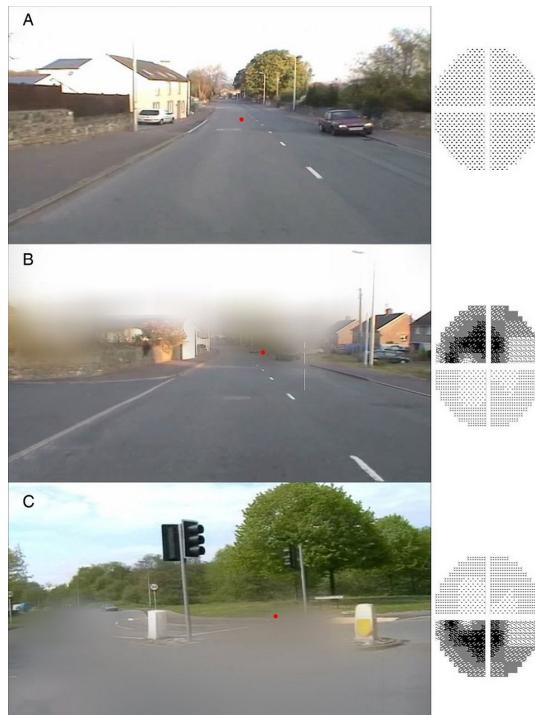


Figura 1.4: Simulación de la pérdida de visión asociada a los resultados de sus pruebas correspondientes. Extraído de [4]

1.2. Motivación

Como se ha comentado anteriormente, las pruebas perimétricas o las campimetrías, miden la sensibilidad visual en puntos de medición definidos mediante patrones de medición. Por lo tanto, solamente se disponen de esos valores en puntos muy concretos. Este trabajo surge de la necesidad de ampliar esta información a lo largo del área total que ocupa la campimetría, con el objeto de tener una idea más aproximada de la calidad de la visión en el campo visual de un paciente. Esto se consigue mediante modelos de interpolación espacial, que permiten, a partir de un conjunto de observaciones, estimar en otros puntos la variable estudiada, en este caso, el defecto visual. El resultado por lo tanto, sería la obtención de unos mapas más precisos del campo visual.

Premisas El presente trabajo parte de la premisa de que los datos con los que se van a trabajar ya han sido previamente estudiados en otros trabajos de fin de máster y es conocido que existen relaciones espaciales entre los puntos de medición de las campimetrías. Esto se demuestra a partir de dos de los índices de autocorrelación más utilizados en estadística espacial; el índice de Moran y el Geary's C. Así, tal como se indica en [13], se realiza un test de significancia de autocorrelación espacial, mediante la realización de simulaciones de montecarlo donde los valores de cada punto son intercambiados aleatoriamente entre sí y se comprueba si bajo estas transformaciones los valores de autocorrelación espacial obtenidos son similares a los del caso real. De los resultados arrojados de estas simulaciones, se obtiene que en base al índice de Moran la hipótesis nula de no existencia de relaciones espaciales es descartada para un nivel de significancia de 0.01 en el 99.29 % de las campimetrías que se emplearon, mientras que empleando el Geray's C esta hipótesis es descartada en el 99.03 % de los casos. Por tanto, partiendo de que existen estas relaciones espaciales, es correcto plantear diversos modelos de interpolación espacial que se detallarán y desarrollarán a lo largo del trabajo.

Hipótesis La principal hipótesis de partida del trabajo consiste en que es posible ajustar un modelo de interpolación global que represente al conjunto de campimetrías. Partiendo de esta, la segunda hipótesis que se propone sugiere que, al agrupar pacientes cuyos defectos en el campo visual sean parecidos y ajustarles modelos de interpolación exclusivos a estas agrupaciones, se conseguiría unos modelos más precisos que al ajustarlos al global de pacientes.

1.3. Objetivos

El principal objetivo del presente trabajo, se centrará en encontrar el mejor modelo de interpolación espacial de los que aquí se presentarán. Este modelo de interpolación permitirá obtener un mapa del campo visual completo, no solamente representados en los puntos de medición de los que consta una campimetría y, con ello, intentar acercarnos a ese modelo ideal de perimetría que se presentó en la introducción, del cual se podrá extraer una mayor cantidad de información. De esta forma, se pretende facilitar la toma de decisiones diagnóstica y un mejor seguimiento y tratamiento de las afecciones del campo visual.

El siguiente objetivo que se presenta, siguiendo la misma linea que el anterior, será ver si se cumple o no la hipótesis de la supuesta mejora de la calidad del modelo a partir del ajuste a diferentes agrupaciones de campimetrías.

Como último objetivo, y ya que para estudiar el anterior será necesario realizar una agrupación de campimetrías, consistirá en obtener una segmentación de pacientes que permita tipificar los defectos visuales. Se pretende, por tanto, clasificar las campimetrías de tal manera que las categorías obtenidas sean coherentes con los defectos típicos de diversas enfermedades que afectan al campo visual, conocidas por los expertos en materia y que han sido estudiadas en detalle. La posibilidad de conocer el defecto típico al que pertenece una campimetría y poder asignarla a una patología conocida, permite facilitar el diagnóstico del paciente y con ello, un mejor seguimiento y tratamiento de la enfermedad.

Capítulo 2

Metodología

Como ya se ha comentado anteriormente, los datos de partida de este trabajo ya han sido previamente tratados, por lo que las líneas en las que se centrará este trabajo serán; por un lado, el ajuste de modelos de interpolación espacial, y por otro, la segmentación de pacientes diferenciando sus defectos visuales que, a su vez, nos permitirá generar otros modelos de interpolación.

El siguiente esquema sintetiza el guión que se va a seguir, en azul los puntos que ya han sido trabajados y, en amarillo, los que se van a trabajar aquí.

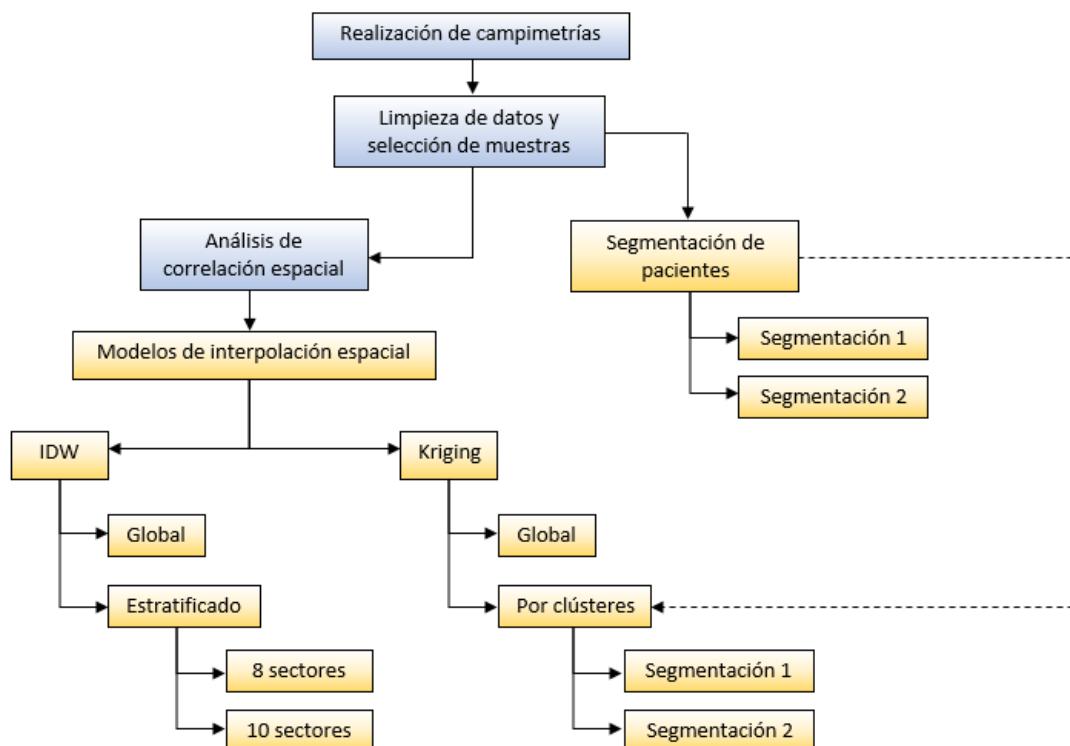


Figura 2.1: Esquema del trabajo

2.1. Presentación de los datos

Tal y como se indica en otros trabajo de fin de máster (TFM) en los que se ha trabajado con los mismos datos (v. g en [13]) los datos originales son una colección de más de 180.000 pruebas de campimetrías visuales proporcionadas por la Unidad de Oftalmología del Hospital Clínico San Carlos. Estas campimetrías se corresponden a las realizadas por dicho servicio durante los últimos quince años. Estos datos han sido recopilados utilizando tanto diferentes dispositivos físicos como diversos protocolos de captura. Así la estructura de los datos no es uniforme, variando la cantidad de puntos considerada entre unos casos y otros, habiendo pruebas que evalúan 20, 59, 74 o 81 puntos. Además estos datos contienen pequeños fallos en los campos de inscripción manual. Este conjunto de datos están previamente procesados, limpiados y corregidos. Por tanto, el conjunto de datos que se va a utilizar en el presente trabajo ya ha sido previamente tratado por el director del mismo.

En concreto, los datos con los que se va a trabajar pertenecen a 5.260 pacientes diferentes en los que se dispone de, al menos, 4 campimetrías por cada uno. Puesto que este trabajo se centra en la parte espacial sin tener en cuenta el aspecto temporal, es decir, sin estudiar la evolución temporal de los pacientes, los conjuntos de entrenamiento, validación y test se van a formar extrayendo en cada uno de ellos una o dos campimetrías de cada paciente. De esta forma, se pretenderá que las muestras sean los más heterogéneas posibles. Más adelante, cuando se presenten los modelos que se van a ajustar, se detallará cómo se realiza esta distribución de conjuntos.

2.1.1. Ubicación de los puntos de medición: Patrón G

Según la patología o el tipo de prueba que se va a realizar, se utilizan patrones diferentes, con los puntos o las ubicaciones de medición dispuestos de diferente manera, según las áreas relevantes que se quieran medir.

Los datos con los que se van a trabajar son campimetrías medidas sobre el patrón denominado con la letra G. En este patrón G hay 59 ubicaciones diferentes dentro de los 30º centrales del campo visual y son distribuidos en un patrón que facilita no solo la detección de la pérdida visual asociada con el glaucoma, sino también enfermedades neurooftalmológicas y maculares. La distribución de las ubicaciones de la prueba en el patrón G sigue los haces de fibras nerviosas de la retina.[17]

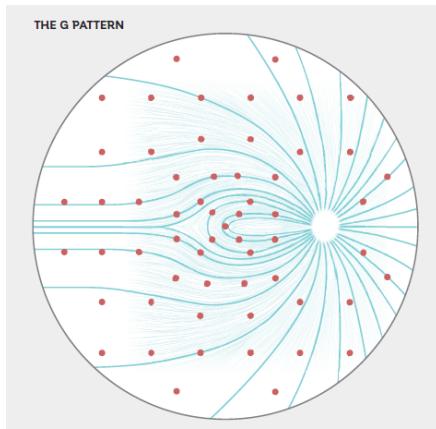
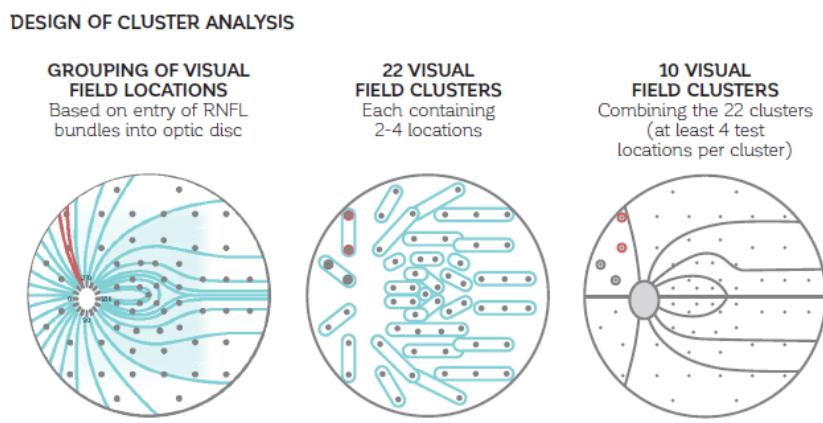


Figura 2.2: Patrón G. Extraído de [17]

Este tipo de distribución se utiliza para lo que se denomina como *análisis clúster*, que consiste en dividir el área del campo visual en sectores. Esta metodología está diseñada para el estudio del glaucoma y es muy sensible a la detección de incluso los defectos más sutiles causados por esta enfermedad. Aprovecha el hecho de que los defectos glaucomatosos consisten en un grupo de defectos adyacentes que se presentan en las ubicaciones del campo visual que corresponden a la rutas que siguen las fibras nerviosas de la retina [8]. De esta forma, el campo visual se divide en 10 sectores. Tal y como se describe en [17] este *análisis clúster* se implementa sobre el patrón G de la siguiente forma; todas las ubicaciones de prueba del patrón G se superponen sobre el mapa de la capa de fibras nerviosas (RNFL) descrito por [14]. A continuación, las ubicaciones del campo visual se agrupan en 22 sectores. Aquellas ubicaciones cuyas respectivas fibras del mapa RNFL que entran en el disco óptico de forma espacialmente próxima se agrupan en el mismo grupo. A continuación se muestra un esquema de cómo se realiza esta agrupación:



The ten Clusters used in the Cluster Analysis are generated by superimposition of the test pattern onto an RNFL map and segmentation into sectors at the optic nerve head (left). Clustering of the visual field locations included in these sectors leads to 22 initial clusters in the G pattern (center), which are further combined into 10 clusters (right).

Figura 2.3: Metodología de agrupación del patrón G en el *análisis clúster*. Extraído de [17]

Esta forma de dividir el campo visual la retomaremos en el capítulo 3, a la hora de realizar la segmentación de pacientes.

Volviendo al patrón G, la posición de los puntos de medición en el conjunto de datos viene dada en coordenadas medidas en $1/10^\circ$, que representan el ángulo con respecto a los ejes x e y y cuyo origen es el punto de fijación intrínseco al aparato de medición. Para facilitar la representación y el manejo de los datos, a través de las diversas librerías y funciones que se van a utilizar, enfocadas al análisis espacial, se van a proyectar estas coordenadas a un sistema de medición planar, eligiendo la proyección *Tranverse de Mercator* como sistema de proyección. Esta proyección cilíndrica y equidistante, respecta la distancia entre paralelos y produce deformaciones en meridianos; exagerando el tamaño real a medida que nos alejamos del ecuador, que en este caso correspondería a al eje horizontal que pasa por el punto de fijación. Puesto que nuestras campimetrías se centran en los primeros 30° , se puede suponer que no se produce grandes deformaciones. Se elige un esferoide de referencia de radio 1 para realizar la proyección. No obstante, hay que hacer hincapié en que este proceso se realiza con el fin de simplificar el manejo de los datos, preservando las relaciones de distancia entre los puntos de distancia, pero que esas unidades de medida son un valor auxiliar, ya que el campo visual se representa en grados.

Por último, en diversos estudios se concluye que no existen diferencias significativas entre ambos ojos más allá de las simetrías entre datos; por esta razón, solo se va a trabajar con muestras del ojo derecho para simplificar la metodología. Las conclusiones extraídas se pueden extrapolar al ojo izquierdo realizando el cambio de simetría correspondiente.

2.1.2. Variable de estudio

En el apéndice A se adjunta la información de la prueba campimetría que proporciona el aparato de medición en detalle. En este apartado nos limitaremos a presentar la variable de estudio con la que se trabajará de aquí en adelante.

Tabla 2.1: Resultados de la campimetría

Coordenada X	Coordenada Y	Valor medido	Valor medio
-	-	-	-

Como ya avanzamos, la prueba campimetría mide la sensibilidad a la luz de un paciente, medida aquí en $1/10$ dB (*Valor medido*). Esta medición se repite en todos los puntos del patrón G, obteniéndose así 59 mediciones. Además de este valor, se dispone del *Valor medio*; este valor representa el valor medio de sensibilidad a la luz de un paciente de la misma edad que al paciente al que se le está realizando la prueba, en la ubicación que se está midiendo. Puesto que las campimetrías disponibles proceden de pacientes de edades dispares, el valor medido no es comparable entre los mismos; por lo tanto, para normalizar este valor, se crea una nueva variable a la que se denominará

como *Defecto visual*, siguiendo la siguiente expresión:

$$\text{Defecto visual} = \text{Valor medido} - \text{Valor medio} \quad (2.1)$$

Un defecto visual positivo indica que el paciente tiene menor sensibilidad a la luz de la que se esperaría para un mismo paciente con su misma edad, mientras que un defecto visual negativo indicaría lo contrario.

2.2. Análisis descriptivo

Se ha comentado previamente, cómo se va a particionar el conjunto de campimetrías en 4 subconjuntos. Aquí se realizará un pequeño análisis centrandonos solamente en la distribución de los defectos visuales definidos anteriormente.

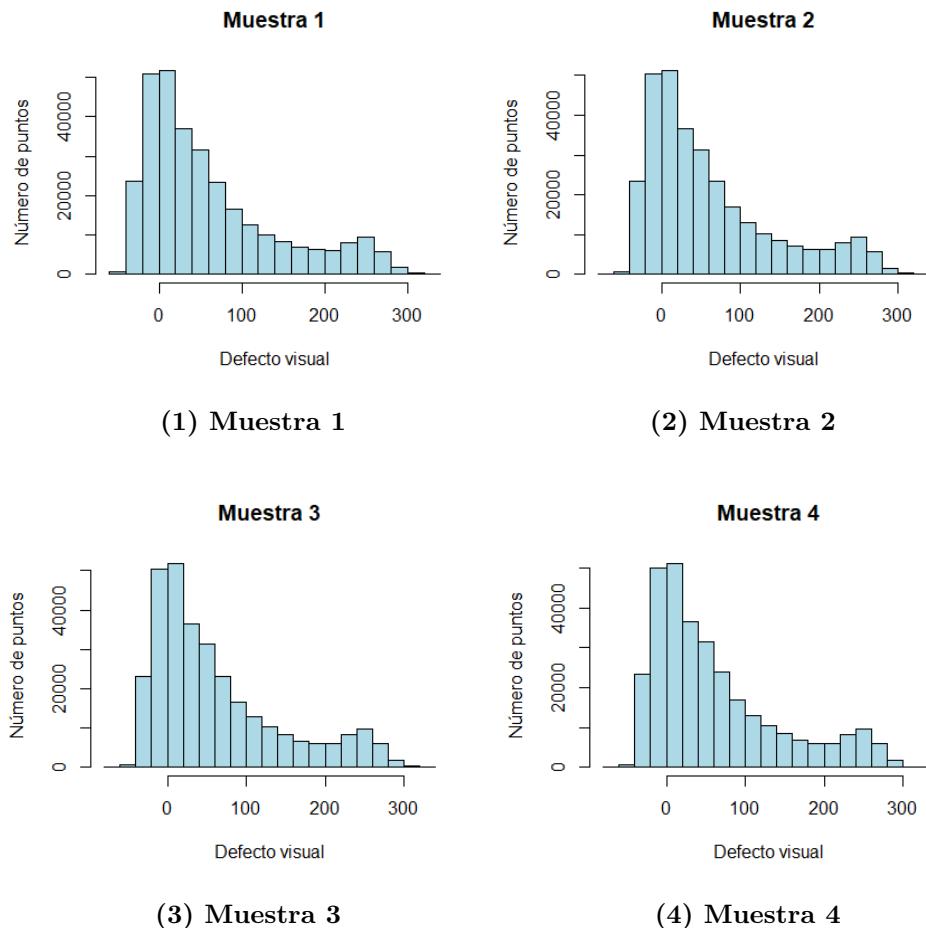


Figura 2.4: Distribución del defecto visual en los puntos de los conjuntos de muestra

La figura figura 2.4 muestra, para cada conjunto de 5260 campimetrías, la distribución del valor de los defectos de cada punto, es decir, de los $59 \cdot 5260 = 310340$ puntos en total. Las muestras son muy similares puesto que aunque se hayan seleccionado

aleatoriamente, los pacientes son los mismos en todas ellas. Se observa cómo, para el total de campimetrías con las que estamos trabajando, la distribución presenta una asimetría positiva, un gran porcentaje se encuentra en torno a 0 e incluso muchos de ellos, con defectos puntuales mayores a la media. El resto de valores en su mayoría presentan defectos menores a 100 y, la cola de la distribución la conforman aquellos puntos con defectos visuales muy elevados, que representan pérdidas de visión totales o casi totales.

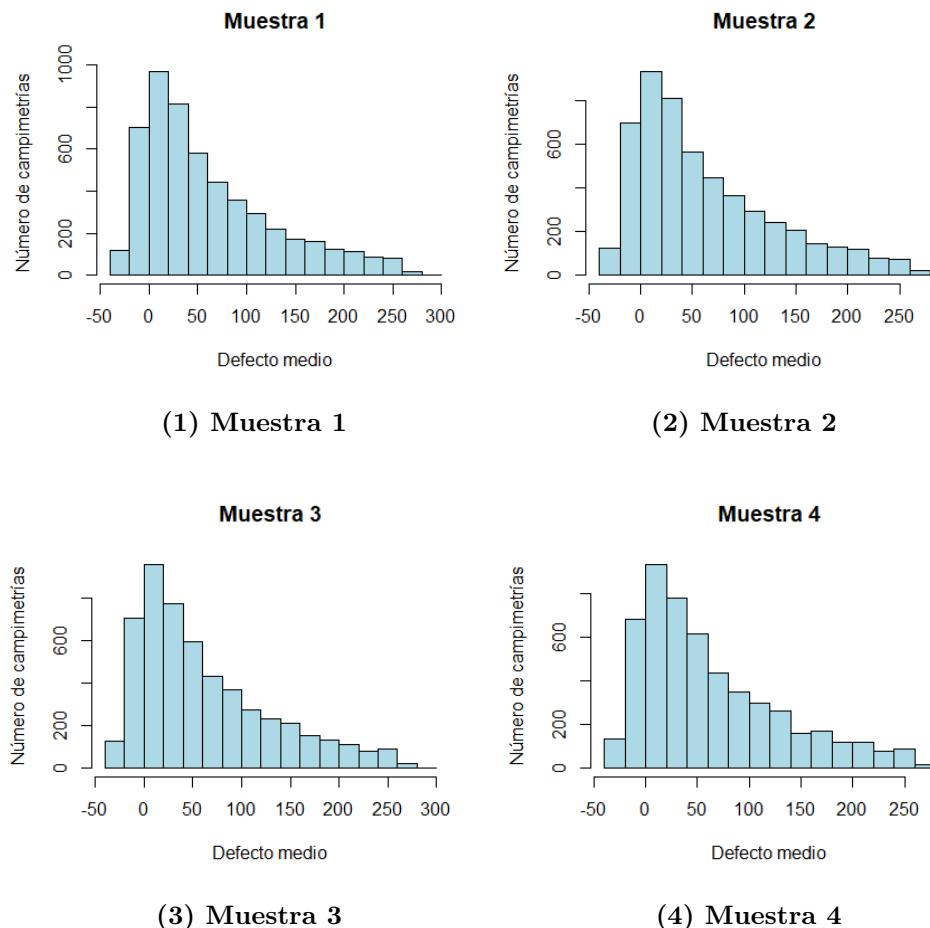


Figura 2.5: Distribución del defecto medio por campimetría de los conjuntos de muestra

La figura figura 2.5 representa los valores medios por campimetría, es decir, cada muestra está compuesta por 5260 valores que representan el defecto medio de las mismas. La forma de las distribuciones es similar a las de la figura 2.4, por lo que la mayoría de la muestra pertenece a pacientes con una visión normal o con defectos medios moderados.

2.3. Técnicas interpolativas espaciales

La interpolación espacial es una materia cuyo objetivo, dado un conjunto de datos espaciales en forma de puntos discretos o subáreas, encontrar la función que mejor representará toda la superficie de estudio y que predecirá valores en otros puntos o para otras subáreas. [12] Ya que nuestros datos se presentan medidos sobre un patrón de puntos de medición, las técnicas utilizadas serán aquellas relativas a interpolación por puntos. En este apartado se expondrá de forma teórica, las dos técnicas interpolativas que se utilizarán a lo largo del presente trabajo. La información de esta sección ha sido extraída de [1]

2.3.1. Métodos de interpolación no geoestadísticos: Inverse Distance Weighted Interpolation (IDW)

La interpolación de ponderación de distancia inversa (IDW) es un método de interpolación espacial que estima valores desconocidos a partir de los puntos más cercanos al punto que se va a estimar.

Esta técnica de interpolación calcula el siguiente promedio:

$$\hat{Z}(s_0) = \frac{\sum_{i=1}^n w(s_i) \cdot Z(s_i)}{\sum_{i=1}^n w(s_i)} \quad (2.2)$$

siendo $\hat{Z}(s_0)$ la estimación del valor de la variable en el punto que se está evaluando, n el número de vecinos considerados en la interpolación e i cada uno de los mismos, y, donde los pesos para las observaciones $w(s_i)$ son calculados de acuerdo con su distancia a la ubicación de la interpolación:

$$w(s_i) = \| (s_i - s_0) \|^{-p} \quad (2.3)$$

donde $\|\cdot\|$ indica la distancia euclídea y p una potencia que pondera la influencia de los puntos teniendo en cuenta la distancia a la que se encuentran del punto de interpolación. Para valores grandes de p , IDW converge a la interpolación del vecino más cercano

2.3.2. Métodos de interpolación geoestadísticos: Kriging

El kriging es un método de interpolación geoestadístico para la estimación de puntos que se sirve del variograma para la estimación de pesos o parámetros.

Correlación espacial: el variograma

En geoestadística, la correlación espacial se explica por el variograma; que calcula la semivarianza en función de la distancia. En el presente trabajo se utilizará variograma como sinónimo de semivariograma. En problemas estadísticos estándar, la correlación se puede estimar a partir de un diagrama de dispersión, cuando tenemos pares de datos de dos variables X, Y . Sin embargo, la correlación espacial entre dos observaciones de una variable $Z(s)$ en las ubicaciones s_1 y s_2 no se puede estimar, ya que solo hay una observación disponible. Una vez asumidos unos supuestos, como la condición de *estacionaridad intrínseca* de los datos, se procede a estimar la correlación espacial entre los mismos a través de un variograma; que se define a través de la siguiente fórmula:

$$\gamma(h) = \frac{1}{2} E(Z(s) - Z(s+h))^2 \quad (2.4)$$

Bajo este supuesto, básicamente se afirma que la varianza de Z es constante, y que la correlación espacial de Z no depende de la ubicación s , sino sólo de distancia de separación h . Entonces, podemos formar múltiples pares $\{z(s_i), z(s_j)\}$ que tienen vectores de separación (casi) idénticos $h = s_i - s_j$ y estiman la correlación entre ellos. Si asumimos además isotropía, que es la independencia de dirección de semivarianza, podemos reemplazar el vector h con su longitud, $\|h\|$. Dada la naturaleza de nuestros datos, se puede hacer esta suposición, pues se puede seleccionar cualquier dirección.

El variograma se puede estimar mediante una muestra N_i de pares de datos $z(s_i)$, $z(s_i + h)$ para un número determinado de intervalos de distancia \tilde{h}_j :

$$\hat{\gamma}(\tilde{h}_j) = \frac{1}{2N_h} E(Z(s_i) - Z(s_i + h))^2, \quad \forall h \in \tilde{h}_j, \quad (2.5)$$

esta estimación se llama variograma muestral.

2.3.3. Estratificación del área de estudio

Consideramos una variable categórica que divide el área de interés en un número de áreas disjuntas, por ejemplo en geología, el tipo de suelo, el uso de la tierra o algún otro factor, es posible que deseemos aplicar krigings separados a los diferentes unidades. Esto se llama kriging estratificado. La razón para hacer kriging por clase puede ser que la estructura de covarianza (semivariograma) sea diferente para los diferentes clases. Uno de los modelos que se va a presentar en el trabajo sigue la línea de esta idea que se acaba de presentar. Como se indicará en el siguiente capítulo, y como ya se adelantó al explicar el patrón G, el dominio espacial de la campimetría se subdivide en zonas de acuerdo a unos criterios optométricos, que actuarán como diferentes estratos de la zona de estudio. Al hacer esta subdivisión, en cada zona no contamos con suficientes pares de puntos para ajustar un modelo de variograma, por lo que no se puede aplicar la técnica de kriging; por lo que la técnica interpolativa que se aplicará será la ya mencionada *IDW*

2.4. Evaluación de la bondad de ajuste de los modelos de interpolación

Para evaluar el poder predictor de los diferentes modelos que se van a estudiar se va a hacer uso de la validación cruzada leave-one-out (*LOOC*); esto significa que, para cada campimetría, se realiza la interpolación con todos los puntos menos el primero, el cual se predice su valor y se compara con el valor real, luego se realiza con el segundo y así sucesivamente. En el caso del método de kriging, si el modelo de variograma refleja adecuadamente la correlación espacial implícita en el conjunto de datos (cada campimetría), el valor predicho por el kriging será próximo al valor observado. Para evaluar esto, se suelen utilizar las siguientes medidas: error medio, error cuadrático medio, error cuadrático medio normalizado (la normalización se realiza dividiendo el residuo entre el error estándar del kriging de la campimetría), correlación entre valor

predicho y observado, correlación entre error normalizado y valor predicho y por último, el porcentaje de errores normalizados por encima de 2.5. [15]

Para evaluar estas medidas recordamos que se desea que el error medio sea lo más cercano a cero, el error cuadrático medio lo más pequeño posible, el error cuadrático medio normalizado lo más cercano a 1, la correlación entre los valores observados y predichos lo más cercana a uno, la correlación entre error normalizado y valor predicho lo más cercana a cero, y el porcentaje de errores normalizados por encima de 2.5 lo menor posible.

Estas medidas se utilizan para evaluar el poder predictivo de estos modelos en cada conjunto de datos, que en este caso corresponde a una campimetría individual. Puesto que se está estudiando un modelo “global”, en el sentido en que el modelo sea común a un conjunto de campimetrías; las medidas de error antes propuestas se van a calcular en cada campimetría del conjunto de validación y luego se va a obtener la media de las mismas. Este “error general” no nos va a proporcionar información acerca de cómo se distribuyen estos errores, pero nos va a servir para estudiar la influencia del número de vecinos escogidos para la interpolación y, además, para hacernos una idea del comportamiento predictivo de los modelos en términos medio. Como se ha adelantado, tanto la interpolación IDW, como la técnica de kriging requiere especificar el número de vecinos que hay que considerar para realizar la interpolación por lo que en primer lugar vamos a ver cómo evolucionan las medidas de error en los diferentes modelos de acuerdo al número de vecinos.

Por último, para poder comparar todos, puesto que el método IDW, al no ser un método geoestadístico, no se puede estimar la variabilidad de las predicciones, lo que supone que no se pueden normalizar los errores de la misma forma que en las técnicas de kriging [9] y, por lo tanto, las únicas medidas antes mencionadas en común son: media de los errores, error cuadrático medio y correlación valor observado-predicho

Conjuntos de entrenamiento, validación y test El ajuste de modelos estadísticos comúnmente requiere el uso de diferentes conjuntos de datos, conjunto de entrenamiento, validación y test. Ya presentamos, los 4 subconjuntos en los que dividimos nuestra muestra de campimetrías. Para este estudio, la definición de los conjuntos de entrenamiento, validación y test, no se entenderá en el sentido tradicional.

Empezaremos por el último, el conjunto de test; éste será común a todos los modelos que vamos a ajustar, para poder comparar la bondad de ajuste de los mismos entre sí, este conjunto lo forma la muestra 4. Para la realización de la segmentación de pacientes se ha reservado la muestra 1, que servirá para realizar un *clustering* para este fin. Como hemos explicado, los modelos de kriging se sirven de un variograma, por lo que para el ajuste del mismo, se va a hacer uso del que se ha denominado *conjunto de entrenamiento*, correspondiente a la muestra 2. La última muestra, la muestra 3, actuará como *conjunto de validación*. La validación como el test no se realizará de la manera tradicional, ya que al tratarse de conjuntos de datos aislados distribuidos de manera espacial, para obtener las medidas de bondad de ajuste se tiene que realizar mediante validación cruzada en cada una de las campimetrías.

Capítulo 3

Segmentación de pacientes

Este apartado abarca tanto la metodología como los resultados de la segmentación de pacientes que aquí se presenta. Puesto que el conjunto de campimetrías no está etiquetado y se desconocen las patologías de las mismas, mediante la técnica de *clustering*, se agrupará el conjunto en diferentes categorías, de forma que los grupos obtenidos representen diferentes tipologías de defectos en el campo visual, asociados a diversas enfermedades.

3.1. Zonificación del campo visual y sus defectos típicos

Dentro de la disciplina de la optometría, se acostumbra a distinguir diversas zonas del campo visual atendiendo a criterios optométricos.

Una de las formas en las que se suele dividir el campo visual, trabajando con este tipo de campimetrías, distingue cuatro cuadrantes y una zona central que ocupa los primeros 20°. Para este trabajo, esta zona central, la dividiremos a su vez en cuatro cuadrantes ya que, como se verá más adelante, diferentes tipos de defectos comunes del campo visual requerirán de esta subdivisión para alcanzar el objetivo de esta sección, la segmentación de pacientes de acuerdo a un defecto tipificado. Así, se han definido 8 sectores de la campimetría, tal y como se muestra en figura 3.11. Más adelante se explicará la metodología utilizada para realizar la segmentación de pacientes, pero adelantamos que la segmentación que utiliza esta zonificación se denominará como *segmentación 1*.

Por otra parte, en el apartado 2.1.1 ya se comentó otra de las formas comúnmente utilizadas de dividir el campo visual, la que se denomina como *análisis clúster* (en esta sección el término clúster hace referencia a un procedimiento distinto). Recordamos que esta subdivisión del área resultaba en 10 sectores diferentes y que esta subdivisión era especialmente útil para estudiar el glaucoma especialmente. La figura 3.12 muestra esta zonificación en los puntos de medición de las campimetrías de estudio. A la segmentación que se realizará utilizando esta forma de dividir el campo visual se denominará como *segmentación 2*.

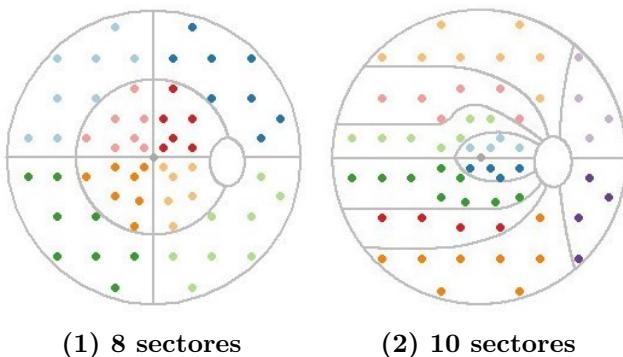
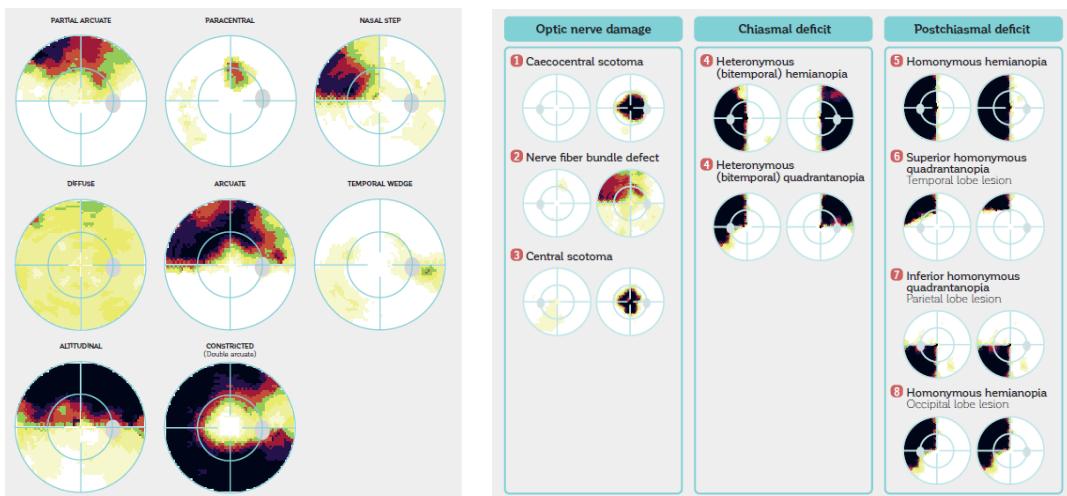


Figura 3.1: Zonificación del campo visual

Defectos típicos del campo visual Las anomalías y defectos visuales han sido ampliamente estudiados por los especialistas en esta materia. Por ello, disponemos de información acerca de cómo se distribuirían típicamente dichos defectos en el campo visual. En las dos figuras que se muestran a continuación, se ve representadas estos comportamientos tanto en la enfermedad del glaucoma como en otras enfermedades neurooftalmológicas.



(1) Defectos típicos del campo visual en el glaucoma

(2) Defectos típicos del campo visual en enfermedades neurooftalmológicas

Figura 3.2: Defectos típicos del campo visual. Figuras extraídas de [17]

La figura 3.21 muestra los defectos visuales más comunes del glaucoma, ordenados según la frecuencia de ocurrencia, son: arqueado parcial, paracentral, nasal, difuso, arqueado, en cuña temporal, altitudinal y constreñido en casos avanzados de glaucoma. Esta tipificación está extraída del estudio [11], en el cual se desarrolla un sistema de clasificación de defectos visuales a partir de un conjunto de perimetrías. Todos estos defectos se manifiestan dentro del campo visual central de 30°.

La figura 3.22 resume la variedad de patrones de defectos de campo visual producidas por diversas condiciones neurológicas. Las subfiguras 1-3 muestran patrones debidos a las lesiones en el disco óptico y en el nervio óptico, que provocan defectos unilaterales (es decir, sólo afectan a un ojo). Enfermedades comunes que provocan este tipo de daño incluyen edema de disco, neuropatías ópticas, neuritis óptica, lesiones compresivas como las causadas por hipertensión intracranal idiopática y una serie de enfermedades congénitas anómalas, como drusas en la cabeza del nervio óptico. Algunas de estas lesiones afectan al estocoma caecocentral y central (subfiguras 1 y 3). Las subfiguras 4-5 muestran lesiones quiasmáticas, cuyos defectos son heterónimos (los dos ojos son imágenes especulares), y pueden afectar al hemisferio vertical (hemianopías) o a un cuadrante (cuadrantopías). Lesiones de este tipo son causadas por enfermedades como la hipófisis, los adenomas y otras lesiones relacionadas. Por último, las subfiguras 5-8 señalan las lesiones postquiasmáticas que, típicamente conducen a defectos homónimos (los dos ojos muestran simetría no specular). El resultado de estas lesiones son hemianopías completas o parciales y quadrantopías inferiores o superiores. [17]. Para asociar los defectos en los que se distingue esta heteronimia u homonimia a las enfermedades que los causan se necesitaría el estudio de ambas campimetrias (ojo derecho e izquierdo) pero puesto que llegar a esta distinción tan precisa de las enfermedades no es el objetivo del presente trabajo, solo nos quedaremos con los defectos básicos.

Aunque no se ha incluido en ninguna de las figuras anteriores, otro de los casos comunes que se pueden encontrar es la pérdida de visión total [11]

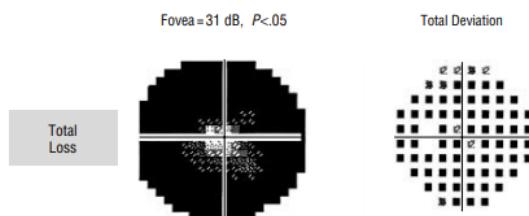


Figura 3.3: Defectos típicos del campo visual: Pérdida total de visión. Extraído de [11]

Como es de suponer, también nos podemos encontrar pacientes completamente sanos que no tengan ningún defecto visual y cuyas campimetrias muestren valores de defecto 0 o incluso que vean por encima del valor de referencia asociado a la edad del paciente.

3.2. Segmentación de pacientes: clustering

El análisis de clusters es un método de agrupamiento de objetos o datos, basado en la similitud de los mismos, de acuerdo con unas características intrínsecas medidas que actúan como variables. Dado que la agrupación en clústeres es popular en muchos campos, existe una gran cantidad de métodos de agrupamiento, siendo quizás los más conocidos, el método k-means y el método jerárquico. La agrupación en clústeres mediante K-means es un enfoque simple y elegante para particionar un conjunto de datos en K grupos distintos y no superpuestos. Este método requiere primero especificar el número deseado de agrupaciones K; entonces el algoritmo de K-medias asignará cada observación en uno de los K grupos [7]. Por otra parte, el método jerárquico no requiere una elección a priori del número K de clústeres y este procedimiento, a su vez, se subdivide en dos; *aglomerativo* y *divisivo*, dependiendo de la estrategia para formar los grupos. No se van a presentar aquí las fórmulas y la metodología en detalle en las que se basan estos algoritmos; recogidos en numerosa bibliografía como por ejemplo en [6]

El criterio utilizado para la elección del algoritmo de clusterización se basa en la necesidad de etiquetar a posteriori otros conjuntos de datos dentro de los grupos obtenidos al realizar la segmentación; pese a que el método de clustering se engloba dentro del aprendizaje no supervisado y, por tanto, no está enfocado a la predicción de nuevos elementos. Sin embargo, y puesto que en este caso se actuará así, se va a elegir el método K-means, ya que este método se apoya en la obtención de unos centroides que “definirán” el resultado de la partición del conjunto de datos. Una manera simple de etiquetar una nueva observación es asignarla al centroide más cercano, pudiendo así conseguir nuestro propósito.

Anteriormente hemos dicho que no se profundizará en la base de estos algoritmos, sin embargo, resumiremos brevemente cómo funciona el algoritmo elegido, basándonos en la información extraída de [10]:

1. Se especifica el número K de grupos o clústeres deseados
2. Se seleccionan aleatoriamente K observaciones del dataset que actuarán como centroides o medias de los clústeres.
3. El resto de observaciones se asignarán al centroide más cercano, basándose, en este caso, en la distancia euclídea de la observación al centroide
4. Para cada uno de los K clústeres se actualiza el centroide calculando el valor medio de las observaciones del clúster en cuestión. El centroide del K_{th} clúster es un vector de longitud p que contiene las medias de las p variables de las observaciones del K_{th} clúster
5. De forma iterativa se minimiza la variabilidad intra-clúster. Esto es, se repiten los pasos 3 y 4 hasta que las asignaciones a los clústeres dejen de cambiar o hasta alcanzar el número máximo de iteraciones

3.2.1. Variables: índices globales

Los índices globales son resúmenes numéricos útiles de la campo visual completo, o de un aspecto del campo visual [2]. Estos índices 1) proporcionan un resumen del estado

del campo visual, 2) son útiles para evaluar objetivamente y clasificar la gravedad de pérdida de campo visual y 3) son útiles en la evaluación del cambio con el tiempo [17]. Para la realización del clustering se van a utilizar dos de estos índices: el defecto medio (MD) y la raíz cuadrada de la pérdida de varianza (sLV) cuyas fórmulas se presentan a continuación:

$$MD = \frac{1}{N} \cdot \sum_{i=1}^N d_i \quad (3.1)$$

$$d_i = n_i - x_i \quad (3.1a)$$

$$sLV = \sqrt{\frac{1}{N-1} \cdot \sum_{i=1}^N (d_i - MD)^2} \quad (3.2)$$

donde N es el número total de puntos de medición y, x_i , n_i y d_i son, respectivamente; el resultado de la prueba de sensibilidad, el valor normal de la prueba de sensibilidad y el defecto visual, medidos sobre el punto de medición i

Estos índices se calculan para cada una de las zonas del campo visual presentadas anteriormente y constituirán las variables que definirán las campimetrías para la realización del *clustering*.

3.2.2. Determinación del número óptimo de clústers

Como se ha comentado anteriormente, se precisa elegir a priori el número K de clústeres. La elección de este número dependerá del objetivo del problema; si este número se desconoce se tratará de obtener mediante una serie de estadísticos o medidas estimados a partir de los datos mismos con el objeto de estimar una partición “natural” del conjunto. Ejemplos de estos métodos serían el método del codo (*elbow*), de la silueta (*silhouette*) o *Gap Statistic*. Sin embargo, la elección del número óptimo de clústeres puede atender a otros criterios; así, si el investigador o el analista conoce de antemano la naturaleza de los datos y los posibles grupos en los que se podría dividir el conjunto, puede aproximar este número K de forma que el resultado de la segmentación sea lo más similar posible a lo que se espera de la misma [6]

Este último criterio es el que se ha utilizado y así, se han ido probando diferentes K números, hasta obtener una segmentación que cubra el mayor número de estos defectos ya tipificados en la sección anterior. Viendo las campimetrías que conformaban los grupos que se formaban y llegando a un compromiso entre el tamaño del clúster, su número y su adecuación a los defectos típicos, se obtuvo que la segmentación óptima para las dos segmentaciones se producía con $K = 12$ clústeres.

3.3. Resultados

Una vez que se han determinado los parámetros y las variables que se van a utilizar para la segmentación, se procede a realizar dicho cálculo. Para ello, se va a utilizar

la función *kmeans* del paquete *stats* del entorno en el que hemos trabajado a lo largo de este trabajo. El conjunto de datos para hacer la segmentación, será uno de los conjuntos de 5260 campimetrías que ya se presentaron en el apartado 2.1, reservado exclusivamente para este propósito. Para cada una de las campimetrías se calculan los dos índices globales presentados en el apartado 3.2.1 para cada una de las zonas del campo visual. Por lo tanto, cada campimetría constará de 16 o 20 variables, dependiendo de la zonificación del campo visual (8 o 10 sectores). Dentro de los algoritmos k-means formulados se escoge el de Hartigan y Wong (1979) ya que ofrece mejores resultados, según la descripción de la misma función. Además, el resultado final del clustering, es sensible a la componente aleatoria en el paso de inicialización de los centroides; por ello se escoge que se realicen 50 inicializaciones diferentes y que se seleccione la que obtenga el mejor resultado, con el objeto de obtener resultados más estables.

3.3.1. Resultado de las segmentaciones de pacientes

Tras hacer la segmentación, las 5260 campimetrías se agrupan en los 12 clústeres, cuyo tamaño se mostrará a continuación:

Tabla 3.1: Tamaño de los clústeres

	Total de campimetrías por clúster											
	C1	C2	C3	C4	C5	C6	C7	C8	C9	C10	C11	C12
Segmentación 1	255	155	911	646	944	223	1116	194	212	245	178	181
Segmentación 2	932	245	582	219	1004	162	174	202	1109	240	161	230

Como dijimos en la sección anterior, los centros se obtienen mediante un proceso iterativo; mencionamos que en la segmentación 1 los centroides finales se obtienen en la iteración 12, y en la segmentación 2, en la iteración 6.

A continuación mostramos la distancia euclídea entre los centros de ambas segmentaciones:

	1	2	3	4	5	6	7	8	9	10	11
2	204.63330										
3	359.18385	551.89990									
4	142.18601	333.06293	225.95656								
5	222.00025	415.25070	141.62514	85.30509							
6	156.11357	294.71625	331.95361	159.55337	210.17880						
7	293.35541	486.71524	67.91036	158.90481	74.05035	270.41263					
8	227.75400	151.92204	527.07505	310.20779	391.13549	287.71176	462.33025				
9	130.72877	253.02441	347.49944	137.73197	210.74229	168.86211	281.74348	200.70883			
10	381.47282	218.50847	696.19548	481.32720	560.72923	427.56498	631.45640	190.81016	365.13549		
11	214.21780	189.50592	503.57929	297.95295	370.47473	191.70709	438.77476	184.54073	210.29320	257.75319	
12	138.14014	235.90995	368.08632	167.06764	241.30871	230.54561	307.03081	197.44291	150.82933	378.06933	268.15249

(1) Segmentación 1

	1	2	3	4	5	6	7	8	9	10	11
2	264.77825										
3	100.15721	167.63927									
4	621.80533	402.36102	533.76244								
5	162.57200	422.69364	259.78241	777.89775							
6	392.81890	220.12872	318.86820	309.79285	543.57849						
7	269.12279	165.31546	192.69688	426.99244	416.39529	299.55496					
8	444.06454	258.84298	360.25561	206.96515	600.51470	213.35533	246.28188				
9	84.53856	345.58301	182.45105	702.74890	79.06077	468.84926	345.96595	525.84543			
10	199.38060	195.06539	162.60643	501.31245	337.01866	223.70762	252.12636	339.49230	265.72622		
11	460.24667	211.43312	366.03147	247.17482	616.44762	234.87834	258.36421	198.81609	540.97335	354.76363	
12	224.62613	160.85185	152.84752	417.30240	380.28248	229.61931	154.57136	228.20109	305.64805	168.98701	299.61365

(2) Segmentación 2

Figura 3.4: Distancia euclídea entre centroides

Hay algunos clústeres cuyos centros están bastante cerca entre sí, por lo que la variabilidad entre ellos no será especialmente grande. Estos pares en la segmentación 1 serían los clústeres: C3 y C7, C5 y C7, C4 y C5 (figura 3.41). Análogamente, para la segmentación 2, los clústeres: C5 y C9, C1 y C9 (figura 3.42)

Tabla 3.2: Medidas del clustering en la segmentación 1

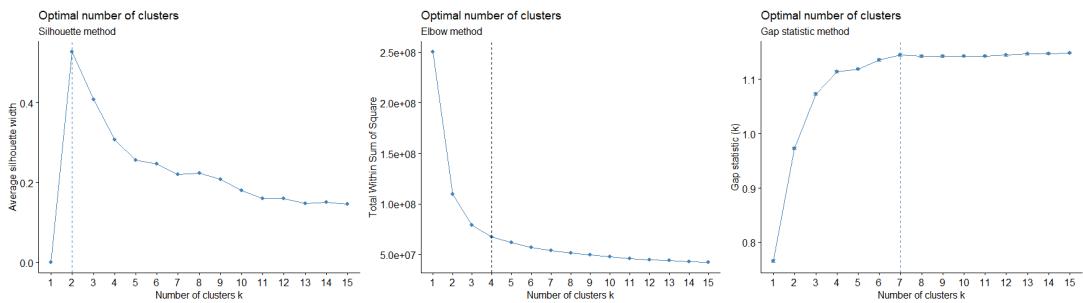
Segmentación 1						
Suma de cuadrados intra-clúster por clúster	C1	C2	C3	C4	C5	C6
	3439325	2663095	1664031	6096400	6081285	3636027
	C7	C8	C9	C10	C11	C12
	3860052	3710524	3496669	3224224	3572133	3309412
Suma de cuadrados intra-clúster en total	44753177					
Suma de cuadrados inter-clúster en total	205517301					

Tabla 3.3: Medidas del clustering en la segmentación 2

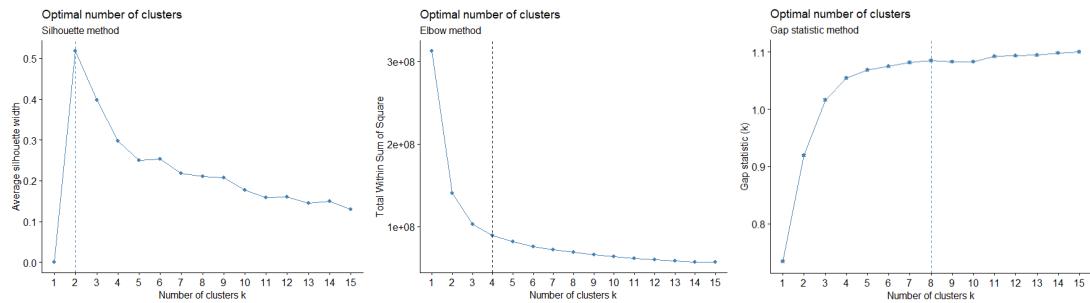
Segmentación 2						
Suma de cuadrados intra-clúster por clúster	C1	C2	C3	C4	C5	C6
	8292492	5074796	7667386	3772726	2534212	4562117
	C7	C8	C9	C10	C11	C12
	4205839	5464321	5306943	4969173	3632061	4562531
Suma de cuadrados intra-clúster en total	60044598					
Suma de cuadrados inter-clúster en total	252427413					

Se observa que la suma de cuadrados intra-clúster en total es menor en la segmentación 1 que en la segmentación 2, con unos valores de 44.753.177 y 60.044.598, respectivamente; esto significa que los clústeres de la segmentación 1 agruparían campimetrías que se parecen más entre sí, que es lo deseable. Para el caso de la suma de cuadrados inter-clúster, se observa que los valores mayores, y por tanto, mejores, serían los que resultan en la segmentación 2, 252.427.413 frente a 205.517.301 de la segmentación 1. Esto indicaría que en la segunda segmentación, los grupos están más diferenciados entre sí, con respecto a la primera segmentación.

También se van a mostrar los estadísticos que se comentaron en el apartado 3.2.2, que se utilizan para determinar el número óptimo de clústeres, aunque aquí no se haga uso de ellos con este fin.



(1) 8 sectores



(2) 10 sectores

Figura 3.5: Método del codo, *Gap Statistic* y Método de la silueta

Estos estadísticos nos sugieren que el número óptimo de clústeres sea bastante menor al que se ha elegido. Sin embargo, realizando la segmentación con menos grupos, no se abarcaba un espectro tan amplio de defectos visuales típicos como utilizando el criterio cualitativo.

Para ilustrar el resultado del *clustering* se va a mostrar a continuación el defecto medio en los puntos de medición de las campimetrías que constituyen cada clúster, a fin de tener una idea general de los mismos. A partir de estas figuras, se va a asignar a cada clúster uno o varios de los posibles defectos visuales típicos a los que se podrían asemejar, presentados anteriormente.

Defecto medio por cluster

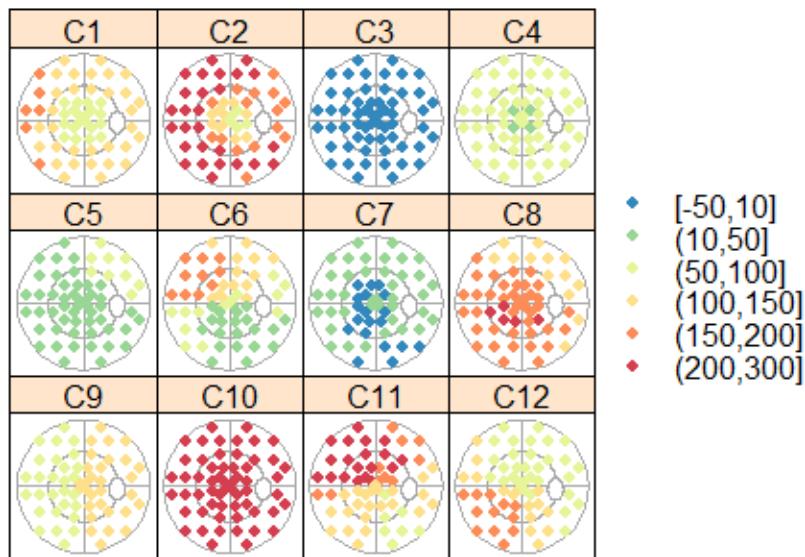


Figura 3.6: Segmentación 1

En la figura 3.6 podemos observar cómo los pares de clústeres, cuyos centros estaban más cercanos, se parecen bastante entre sí en cuanto a la distribución espacial, diferenciándose más bien en la magnitud del defecto visual. Recordemos los pares: C3 y C7, C5 y C7, C4 y C5.

Tabla 3.4: Equiparación de los clústers a su defecto visual (Segmentación 1)

Segmentación 1	
Clúster	Possible defecto visual
C1	Defectos en los haces del nervio óptico (Enfermedades neurooftalmológicas) o Constreñido en fase temprana (Glaucoma)
C2	Constreñido (Glaucoma)
C3	Visión normal
C4	Difuso (Glaucoma)
C5	Difuso (Glaucoma)
C6	Nasal (Glaucoma), cuadrantopía superior (Enfermedades neurooftalmológicas) o defectos en los haces del nervio óptico (Enfermedades neurooftalmológicas)
C7	Difuso (Glaucoma)
C8	Hemianopía (Enfermedades neurooftalmológicas) o pérdida de visión total
C9	Hemianopía (Enfermedades neurooftalmológicas)
C10	Pérdida de visión total
C11	Arqueado parcial, arqueado o altitudinal (Glaucoma)
C12	Cuadrantopía inferior (Enfermedades neurooftalmológicas)

Defecto medio por cluster

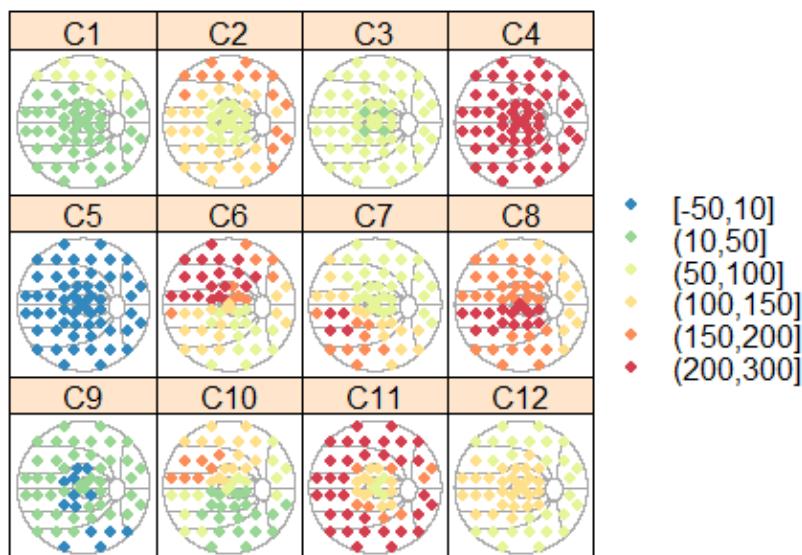


Figura 3.7: Segmentación 2

La figura 3.7 muestra igualmente los pares de clústeres, cuyos centros están más cerca entre sí, interpretándose igual que la figura 3.6. En este caso los pares son: C5 y C9, C1 y C9.

Tabla 3.5: Equiparación de los clústeres a su defecto visual (Segmentación 1)

Segmentación 1	
Clúster	Possible defecto visual
C1	Difuso (Glaucoma)
C2	Arqueado parcial (Glaucoma)
C3	Difuso (Glaucoma)
C4	Pérdida de visión total
C5	Visión normal
C6	Arqueado parcial, arqueado o altitudinal (Glaucoma)
C7	Cuadrantopía inferior (Enfermedades neurooftalmológicas)
C8	Hemianopía (Enfermedades neurooftalmológicas) o pérdida de visión total
C9	Difuso (Glaucoma)
C10	Nasal (Glaucoma), cuadrantopía superior (Enfermedades neurooftalmológicas) o defectos en los haces del nervio óptico (Enfermedades neurooftalmológicas)
C11	Constreñido (Glaucoma)
C12	Defectos en los haces del nervio óptico (Enfermedades neurooftalmológicas)

Además, a la vista de la (figura 3.6) y la (figura 3.7), se observa que en las dos segmentaciones se forman clústers muy similares e incluso casi idénticos. Enumeramos estas correspondencias en la siguiente tabla:

Tabla 3.6: Correspondencias entre clústeres de las dos segmentaciones

Segmentación 1	Segmentación 2
C1	-
C2	C11
C3	C5
C4	C3
C5	C1
C6	C10
C7	C9
C8	C8
C9	-
C10	C4
C11	C6
C12	C7

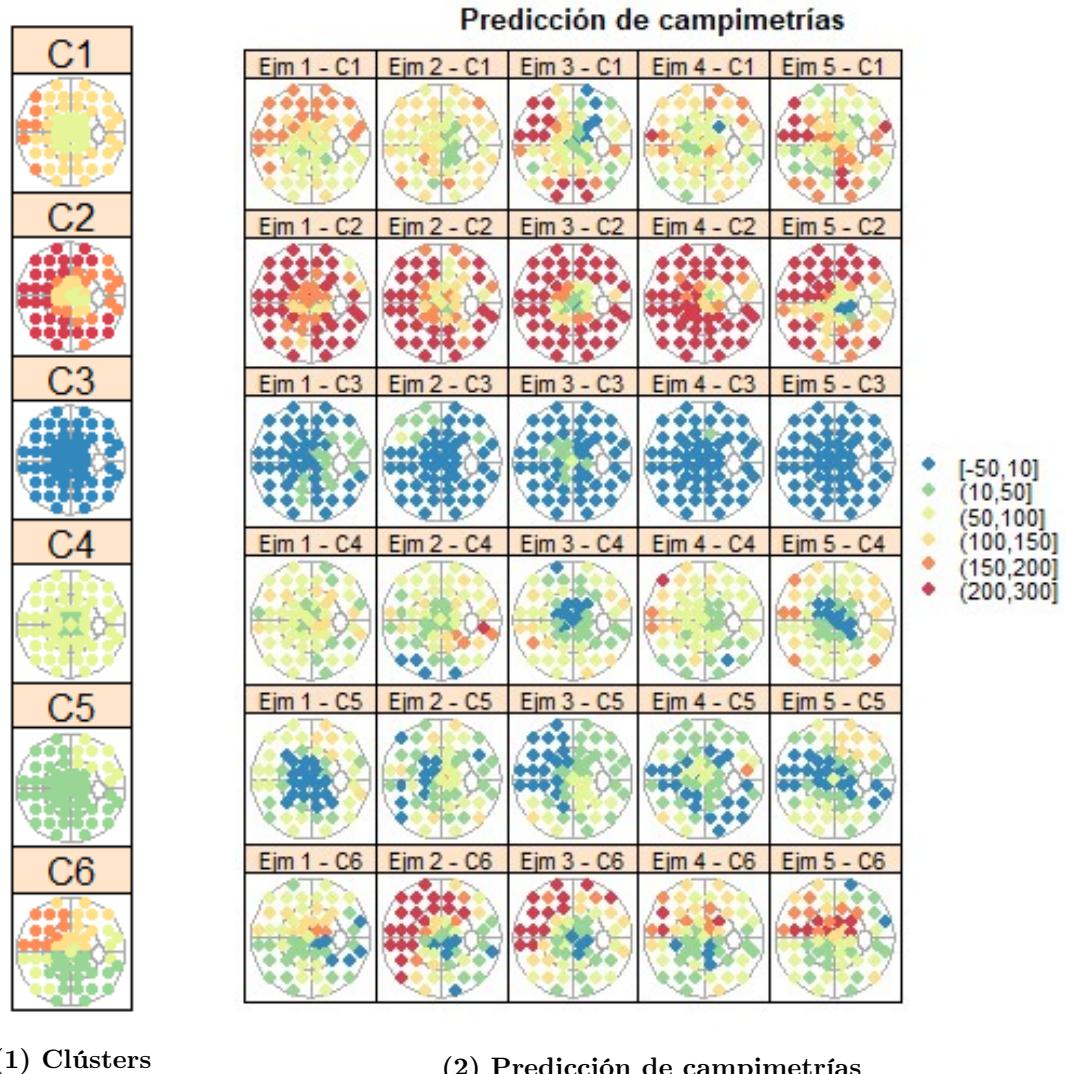
Los únicos defectos que no se ven representados en ninguna de las dos segmentaciones son aquellos que afectan al escotoma (estocoma caecocentral y central), y, en la segmentación 2, tampoco se ve representadas las hemianopías, pero este resultado es consecuente a que la zonificación en 10 sectores presentada anteriormente está diseñada, como ya se dijo, para la detección de defectos asociados al glaucoma.

Una vez hecha la segmentación, de clasifican en estos clústeres los conjuntos de validación y test y, se comprueba que, efectivamente, realizando la misma representación presentada en la figura anterior, se obtienen resultados prácticamente idénticos.

3.3.2. Ejemplos de predicción de campimetrías

Por último, se va a mostrar la predicción de 5 campimetrías por clúster, escogidas al azar de otro de los conjuntos de 5260 campimetrías, para ver en qué clúster las clasifica. Realizamos esto primero con la segmentación 1 y después con la segmentación 2.

Segmentación 1



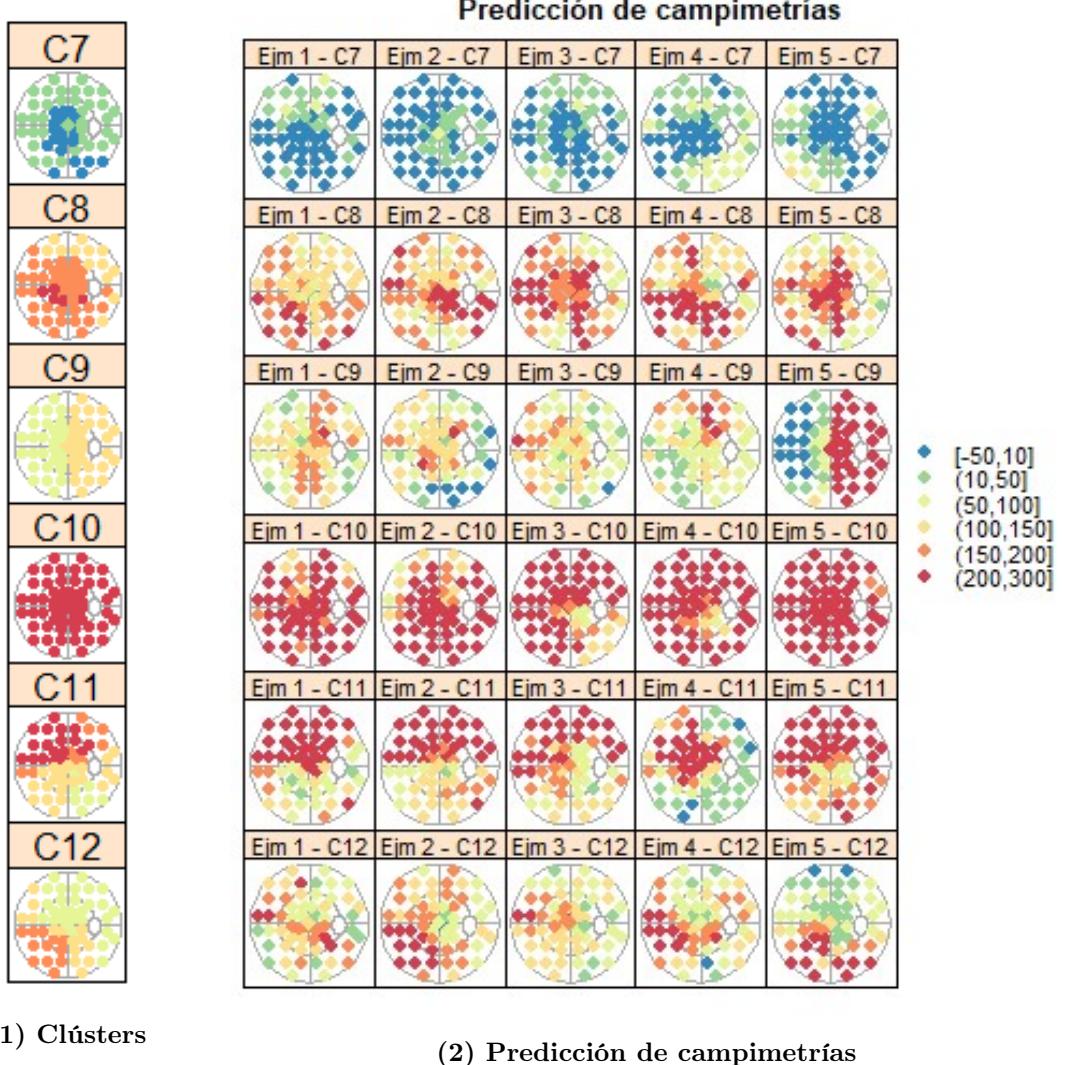


Figura 3.9: Segmentación 1: Predicción de campimetrías (ii)

A la vista de la figura 3.8 y la figura 3.9, vemos cómo cada campimetría tiene una naturaleza distinta y a veces no muestra un patrón definido. Sin embargo, en la mayoría de los casos la predicción nos encaja con el clúster en la que lo agrupa. En los clústeres que se citaron como muy parecidos entre sí, por la cercanía entre sus centroides, algunas de las campimetrías podrían pertenecer a uno u otro grupo, esto se hace evidente en el caso de los clústeres C5 y C7, por ejemplo.

Segmentación 2

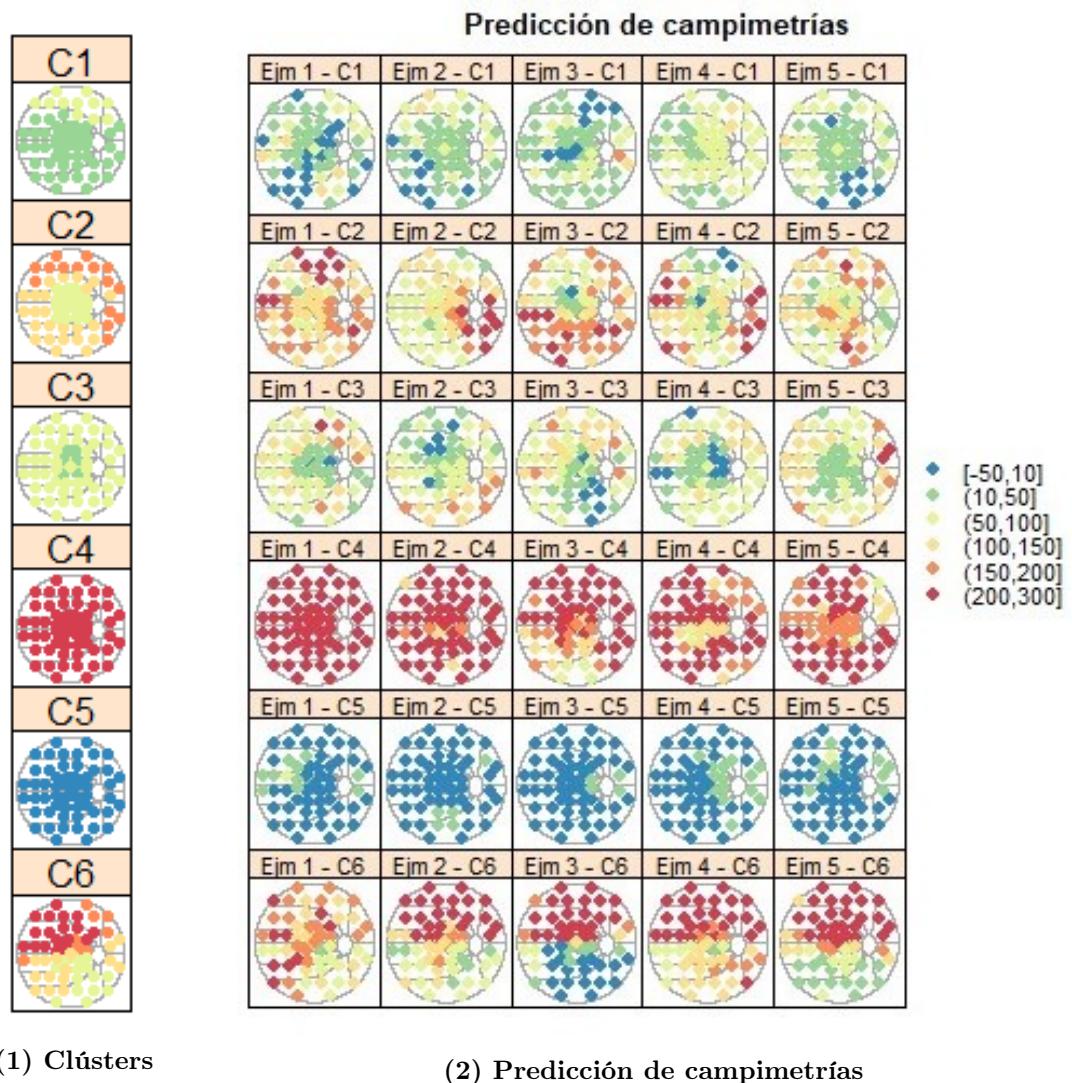


Figura 3.10: Segmentación 2: Predicción de campimetrías (i)

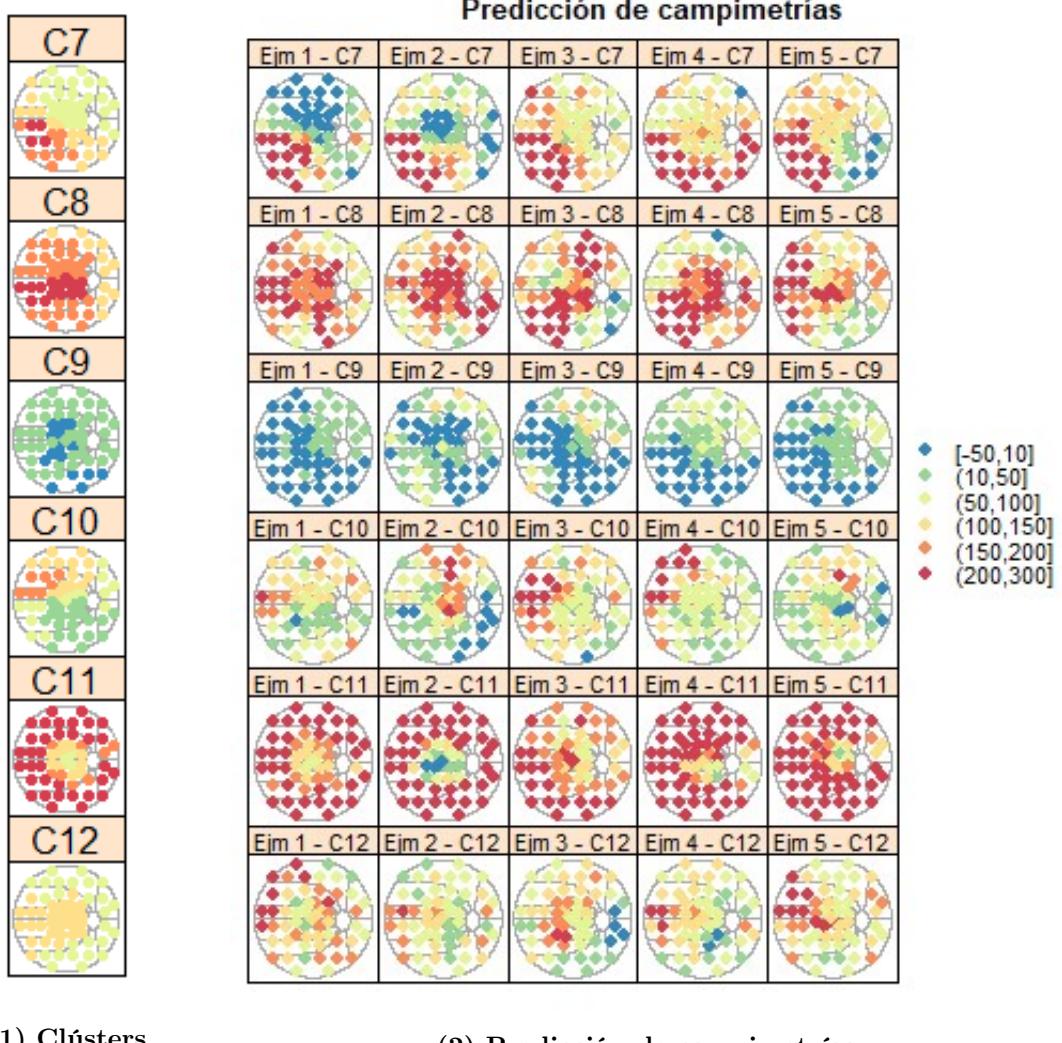


Figura 3.11: Segmentación 2: Predicción de campimetrías (ii)

Estas dos figuras se interpretan de forma similar a las correspondientes a la anterior segmentación, por lo que no se añadirá ningún otro comentario.

Capítulo 4

Modelos interpolativos

En este capítulo se ajustarán los modelos teóricos explicados en el capítulo 2 a nuestros conjuntos de campimetrías. Estos modelos están implementados en el paquete *gstat* de R, especializado en geoestadística. Además para trabajar con este tipo de datos con componente espacial se ha utilizado otras librerías auxiliares especializadas en Sistemas de información geográfica (SIG)

4.1. IDW global

El primer modelo que se va a presentar es el que se denominará como IDW global; este modelo corresponde con la interpolación IDW, (comentado en el capítulo 2), mediante validación cruzada *LOOCV* sobre el conjunto de entrenamiento, se pretende obtener los parámetros que arrojen mejores resultados en cuanto a su capacidad predictiva. Para ello se realiza este procedimiento en una serie de n vecinos desde 1 hasta 15 y, a su vez, con una secuencia de 1 hasta 5 con un salto de 0.25, del parámetro p , que pondera la influencia de los puntos vecinos (ecuación (2.3)).

Para ilustrar cómo evolucionan las medidas de error respecto al número de vecinos, se realiza la media de las medidas agrupando por los mismos.

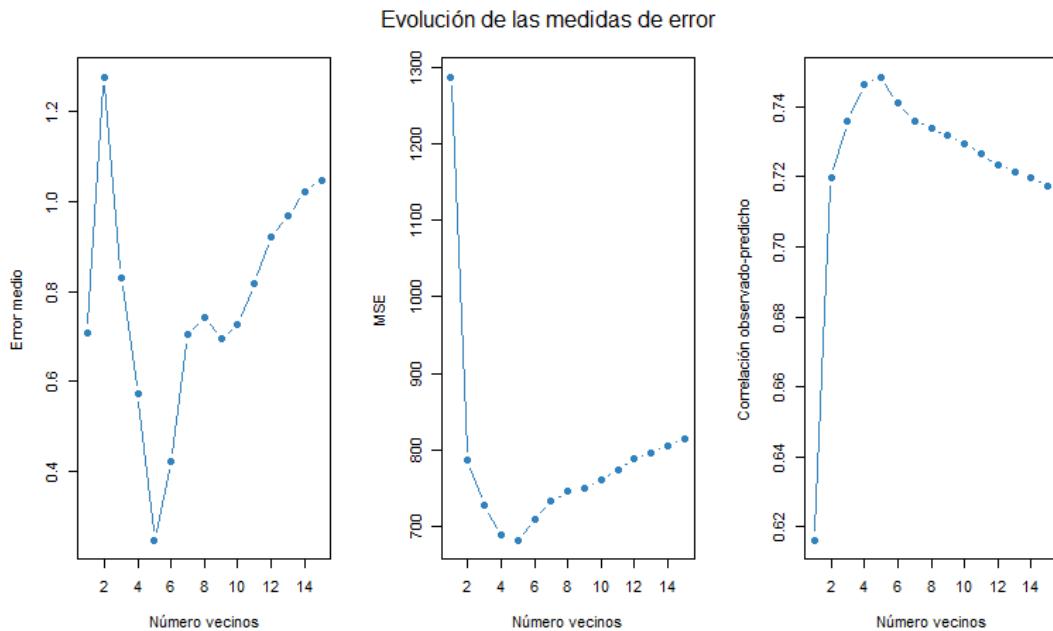


Figura 4.1: Evolución de las medidas de error con respecto al número de vecinos. IDW

Como se puede apreciar en la figura figura 4.1, el valor óptimo se alcanza en $n = 5$ vecinos, pues todos los errores considerados se hacen mínimos

Extrayendo los resultados de la combinación del número de vecinos y el parámetro p , observamos en la siguiente tabla que las diferencias de las medidas de error son del orden de unidades e incluso décimas, por lo que se va a optar por elegir aquella combinación que engloba los tres mejores valores: $n = 5$ y $p = 2$

Tabla 4.1: IDW Global: media de errores sobre el conjunto de Validación

Media de errores				
n	p	Error medio	MSE	Correlación Observado-Predicción
5	1.25	-0.0923	687.6662	0.7480
5	1.50	-0.0393	680.7424	0.7500
5	1.75	0.0135	675.3867	0.7515
5	2.00	0.0659	668.1817	0.7525
5	2.25	0.1176	669.1842	0.7529
5	2.50	0.1684	669.8660	0.7529

Por último, establecidos los parámetros del modelo, se realiza la validación cruzada sobre el conjunto de campimetrías de test, común a todos los modelos, para poder compararlos posteriormente. Se muestran tanto los valores medios de las campimetrías

como el histograma que representa las medidas de error y el porcentaje del conjunto de campimetras.

Tabla 4.2: IDW Global: media de errores sobre el conjunto de Test

Media de errores				
n	p	Error medio	MSE	Correlación Observado-Predicción
5	2.00	0.1246	672.7910	0.7478

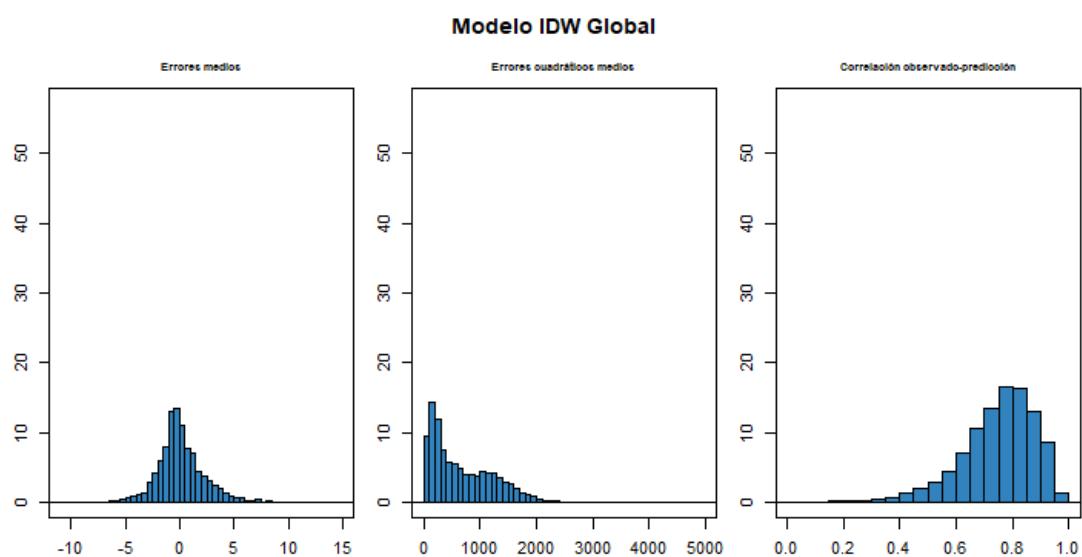


Figura 4.2: Distribución de las medidas de error. IDW

Se observa que los errores medios se encuentran en torno a 0, igual que el error cuadrático, y además, que las frecuencias máximas de las correlaciones entre los valores observados y las predicciones están por encima del valor 0.7

4.2. IDW estratificado

En este apartado se presenta el modelo al que se ha denominado *IDW estratificado*. Este modelo, requiere que la interpolación IDW se calcule aisladamente en cada estrato y luego se agrupen todos los resultados para obtener el conjunto completo. Esta sección se subdividirá, a su vez, en los resultados de este modelo haciendo la estratificación del dominio siguiendo las dos formas de subdividir el área de la campimetría, propuestas en el apartado 3.1, que aquí se tratarán como *zonificación en 8 sectores* y *zonificación en 10 sectores*. Para simplificar, se ha optado por no realizar la validación cruzada en el conjunto de datos de entrenamiento, como en el anterior modelo; ya que habría que hacerlo estrato por estrato, por lo que se han tomado los mismos parámetros que se eligieron para el modelo anterior: $n = 5$ y $p = 2$, al ser estos los óptimos para el modelo general. Por lo tanto, se pasará directamente a mostrar los resultados obtenidos sobre el conjunto de datos de test.

4.2.1. Zonificación en 8 sectores

Media de errores				
n	p	Error medio	MSE	Correlación Observado-Predicción
5	2	1.1281	837.4215	0.4717

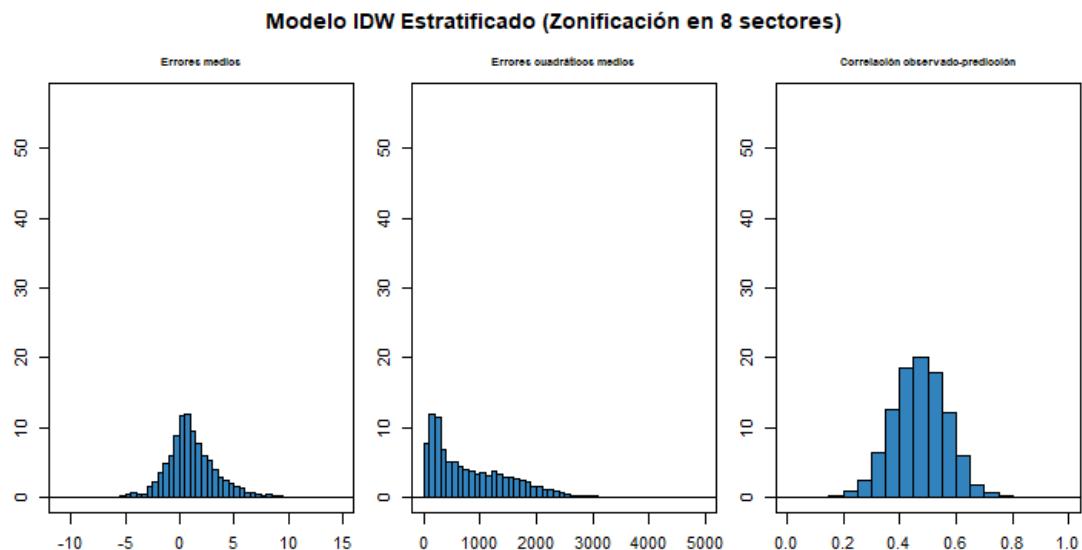


Figura 4.3: Distribución de las medidas de error. IDW estratificado 8 sectores

Las dos primeras gráficas se interpretan de manera similar a las de la figura 4.2. En cambio, se observan peores valores de la correlación entre los valores observados y la predicción, donde las frecuencias máximas ahora se sitúan en torno al 0.4 y 0.6.

4.2.2. Zonificación en 10 sectores

Media de errores				
n	p	Error medio	MSE	Correlación Observado-Predicción
5	2	0.6356	999.3133	0.5756

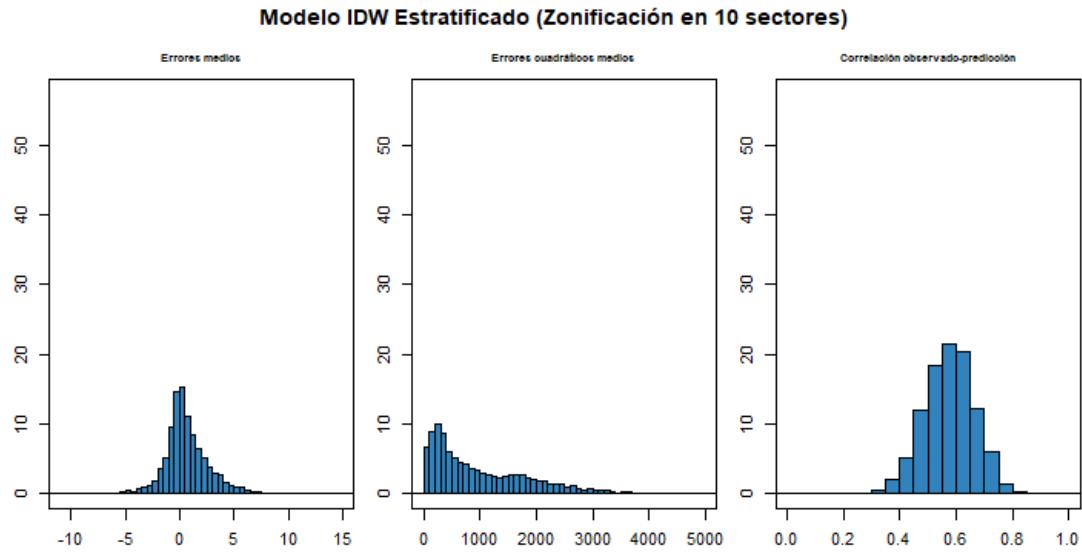


Figura 4.4: Distribución de las medidas de error. IDW estratificado 10 sectores

La gráfica de la derecha, muestra cómo en este modelo mejoran ligeramente las correlaciones entre las observaciones y las predicciones, lo que indica una mejoría en el ajuste con respecto al modelo anterior.

4.3. Kriging global

Ahora vamos a presentar el modelo que se denominará *Kriging global*. Como se explicó en el apartado 2.3.2, primero se requiere ajustar un modelo de variograma al variograma muestral. Puesto que el objetivo del trabajo es obtener un modelo estándar para todas las campimetrias, la forma en la que se va a tratar de alcanzar este propósito en el presente modelo es la siguiente: calcular un variograma muestral en el que en cada una de las semivarianzas es la media de todas las semivarianzas del conjunto de entrenamiento. Esto es, se calculan todos los variogramas del conjunto de entrenamiento y, en cada intervalo de distancia, se calcula la media del total. Hay que tener en cuenta, que los puntos de medición no se reparten uniformemente, por lo que la distancia entre pares de puntos no es la misma a lo largo del patrón de medición; por este motivo hay que ser cuidadoso a la hora de elegir los intervalos de distancia, evitando capturar la variabilidad local de aquellos puntos más próximos entre sí. Pese a que los modelos de *kriging global por clústeres* se presentan en la siguiente sección, se hace el siguiente inciso: para poder comparar el poder predictivo de este modelo con los que acabamos de citar, este “variograma medio” no se va a hacer con todas las campimetrias del conjunto de entrenamiento, si no que se van a seleccionar 500 aleatoriamente, ya que realizando este mismo procedimiento en los diferentes clústeres que han resultado de la segmentación, el tamaño muestral del conjunto se divide entre los mismos. De esta forma se pretende equilibrar la desventaja del menor número de muestras en el modelo de *kriging global por clústeres*.

Una vez obtenido este variograma, vamos a ajustar los siguientes modelos teóricos más comunes de variograma: exponencial, esférico, gaussiano, lineal y circular. El ajuste del modelo se realiza mediante mínimos cuadrados ponderados, donde los pesos utilizados responden con N_j/h_j^2 , donde N_j es el número de pares de puntos dentro del intervalo de distancia j y h es la distancia del mismo, que son métodos empíricos [16].

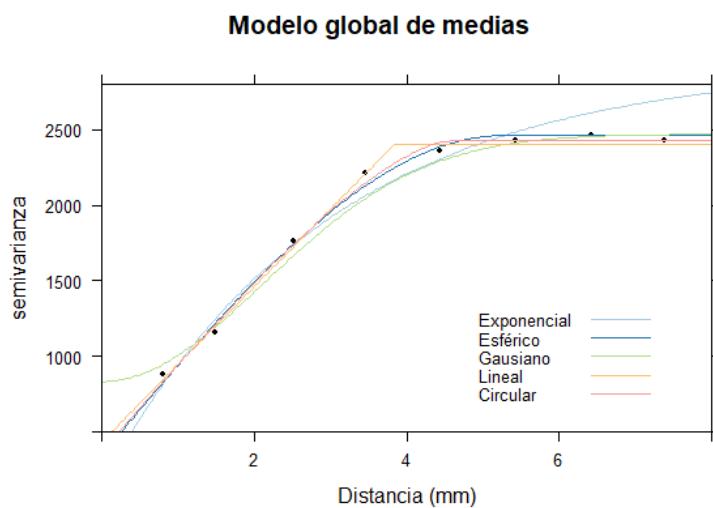
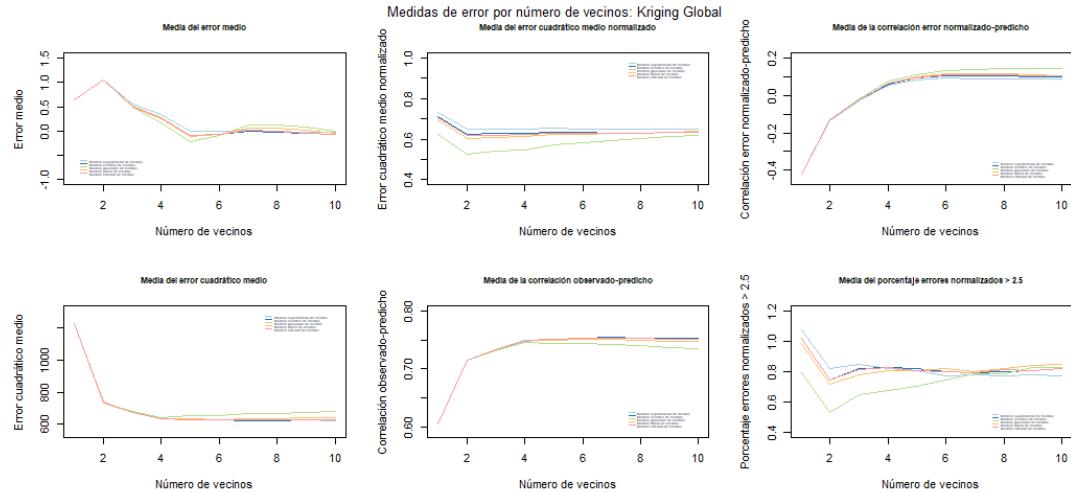


Figura 4.5: Semivariograma de medias ajustado a distintos modelos

Una vez ajustado los modelos al conjunto de entrenamiento, se va a elegir, tanto el modelo de variograma, como el número de vecinos, mediante validación cruzada *LOOCV* en el conjunto de validación. Como se mencionó en el apartado 2.4, este tipo

de modelos se pueden evaluar con más medidas de error, por lo que, al hacer estas elecciones, se van a tener todas en cuenta, procediendo análogamente al primer modelo presentado.



De acuerdo con las gráficas anteriores, se establece que el número óptimo de vecinos en $n = 6$ y, apoyándonos en la siguiente tabla, el modelo exponencial que se ajustó previamente, será el modelo elegido, pues minimiza el error medio, y el resto de medidas son ligeramente mejores que en los otros modelos, si se observa de forma conjunta.

Tabla 4.3: Kriging global: media de errores sobre el conjunto de Validación

Media de errores					
Medida de error	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.0073	-0.0588	-0.0934	-0.0667	-0.0632
Error cuadrático medio	628.1879	626.2401	658.0031	631.7713	627.4849
Error cuadrático medio normalizado	0.6512	0.6323	0.5832	0.6246	0.6290
Correlación observado-predicción	0.7527	0.7541	0.7444	0.7520	0.7537
Correlación predicción-error normalizado	0.0916	0.1068	0.1327	0.1151	0.1099
Porcentaje errores normalizados >2.5	0.7763	0.8000	0.7492	0.8237	0.8034

A continuación se muestran los valores medias y los histogramas de las medidas de error (las comunes a todos los modelos presentados) sobre el conjunto de test:

Tabla 4.4: Kriging global: media de errores sobre el conjunto de Test

Media de errores				
Modelo	n	Error medio	MSE	Correlación Observado-Predicción
Exponencial	6	0.0004	643.3256	0.7597

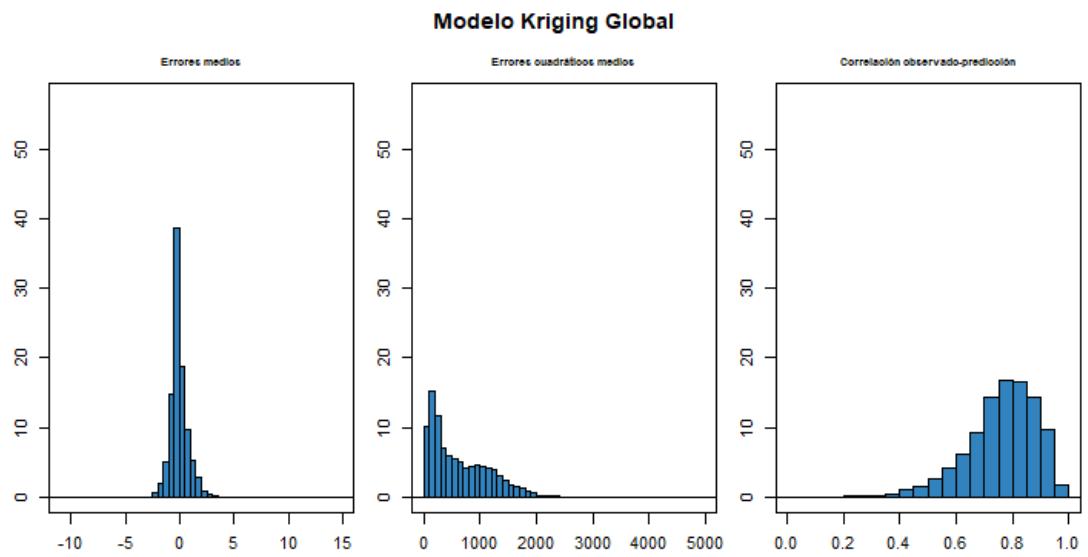


Figura 4.6: Distribución de las medidas de error. Kriging Global

En la figura 4.6, se observa como en el ajuste *kriging global* realizado, la distribución de errores medios es claramente leptocúrtica con media en 0. La distribución de los errores cuadráticos medios tiene su mayor frecuencia para valores menores a 1000, y las correlaciones entre los valores observados y las predicciones tiene una distribución en torno a 0.8.

4.4. Kriging global por clústeres

El modelo al que se ha denominado como *Kriging global por clústeres* atiende a la misma metodología del modelo antes presentado; es decir, se van a seguir los mismos pasos pero en vez de generar un modelo único para todas las campimetrías, se va a ajustar un modelo por cada clúster de pacientes de la segmentación realizada en el Capítulo 3. Este apartado, por tanto, se divide en dos; uno para cada segmentación de pacientes. Los resultados de los pasos correspondientes a la elección de modelos de variograma y número de vecinos por clúster se incluyen en el Apéndice B y aquí, nos vamos a limitar a presentar los modelos elegidos por clúster y los resultados sobre el conjunto de datos de test.

4.4.1. Segmentación 1

A continuación se presenta la tabla con los modelos que se han seleccionado para cada clúster de la segmentación 1

Tabla 4.5: Segmentación 1: Modelos seleccionados

Modelos seleccionados		
Cluster	Vecinos	Modelo
C1	6	Circular
C2	8	Exponencial
C3	3	Gausiano
C4	5	Gausiano
C5	4	Esférico
C6	7	Exponencial
C7	4	Exponencial
C8	8	Exponencial
C9	4	Exponencial
C10	4	Exponencial
C11	8	Esférico
C12	8	Exponencial

La siguiente tabla recoge las medidas de error medias por cada clúster para la segmentación 1:

Tabla 4.6: Kriging global por clústeres - Segmentación 1: Media de errores en el conjunto de Test

Media de errores				
Cluster	Error medio	MSE	Correlación Observado-Predicción	
C1	0.2852	1234.5060		0.8028
C2	-0.1607	1075.0820		0.8667
C3	-0.0888	118.7829		0.6954
C4	-0.0017	878.1165		0.7278
C5	0.1450	521.7685		0.7475
C6	-0.0252	1179.1240		0.8632
C7	0.0183	281.3927		0.7381
C8	-0.7248	1320.6020		0.7979
C9	-0.7847	1263.4720		0.7258
C10	-1.0651	699.2420		0.7706
C11	-0.1569	1366.4890		0.8513
C12	-0.0426	1226.6840		0.8408

Por último, se presenta el histograma de errores, pero en vez de presentar un histograma por cada clúster, el histograma recoge todos los errores de las campimetrías del conjunto de test, con el fin de que estas figuras puedan compararse entre los modelos presentados en el trabajo.

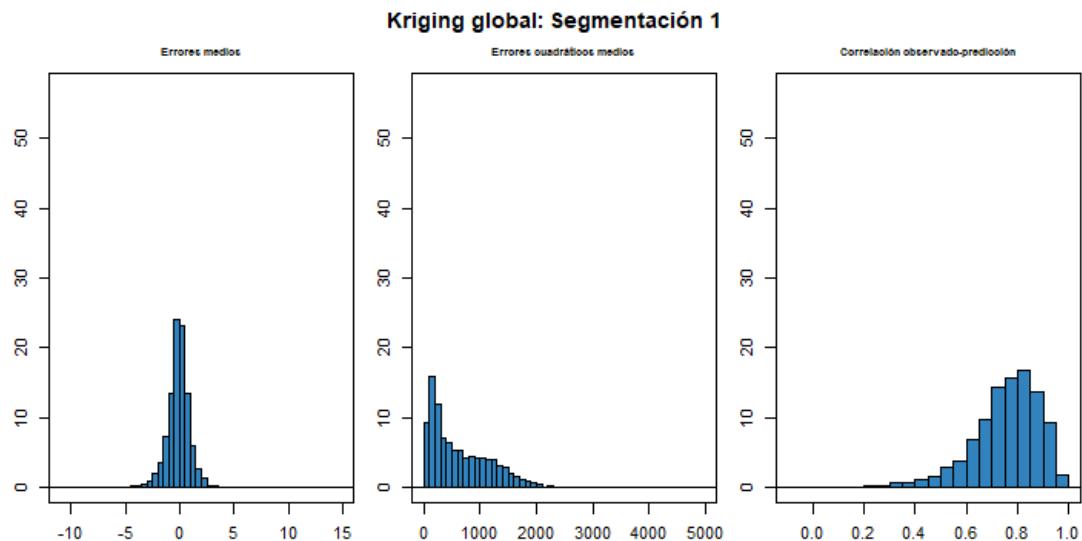


Figura 4.7: Distribución de las medidas de error. Kriging global: Segmentación 1

Las dos últimas gráficas de la figura anterior, se interpretan de forma semejante a la figura 4.6, respecto a la distribución de los errores medios, también está en torno al 0 pero es menos leptocúrtica que la anterior.

4.4.2. Segmentación 2

Al igual que antes, primero se presenta la tabla con los modelos seleccionados, en este caso, en la segmentación 2

Tabla 4.7: Segmentación 2: Modelos seleccionados

Modelos seleccionados		
Cluster	Vecinos	Modelo
C1	6	Esférico
C2	8	Esférico
C3	5	Gausiano
C4	4	Esférico
C5	7	Gausiano
C6	8	Exponencial
C7	8	Exponencial
C8	8	Exponencial
C9	4	Exponencial
C10	8	Exponencial
C11	5	Lineal
C12	5	Exponencial

Análogamente, se muestra la siguiente tabla que recoge las medidas de error medias por cada clúster para la segmentación 2:

Tabla 4.8: Kriging global por clústeres - Segmentación 2: Media de errores en el conjunto de Test

Media de errores			
Cluster	Error medio	MSE	Correlación Observado-Predicción
C1	-0.1127	545.3829	0.7466
C2	-0.3932	1210.0740	0.8089
C3	0.0380	902.7920	0.7305
C4	-1.0680	660.1745	0.7585
C5	-0.2547	116.8991	0.7216
C6	-0.1991	1385.6600	0.8577
C7	-0.2277	1180.6430	0.8575
C8	-0.8877	1258.2900	0.8114
C9	0.0666	294.4661	0.7432
C10	-0.0779	1130.6890	0.8601
C11	0.7689	1074.5520	0.8616
C12	-0.8802	1315.4080	0.7254

Por último, el histograma de errores del conjunto de test

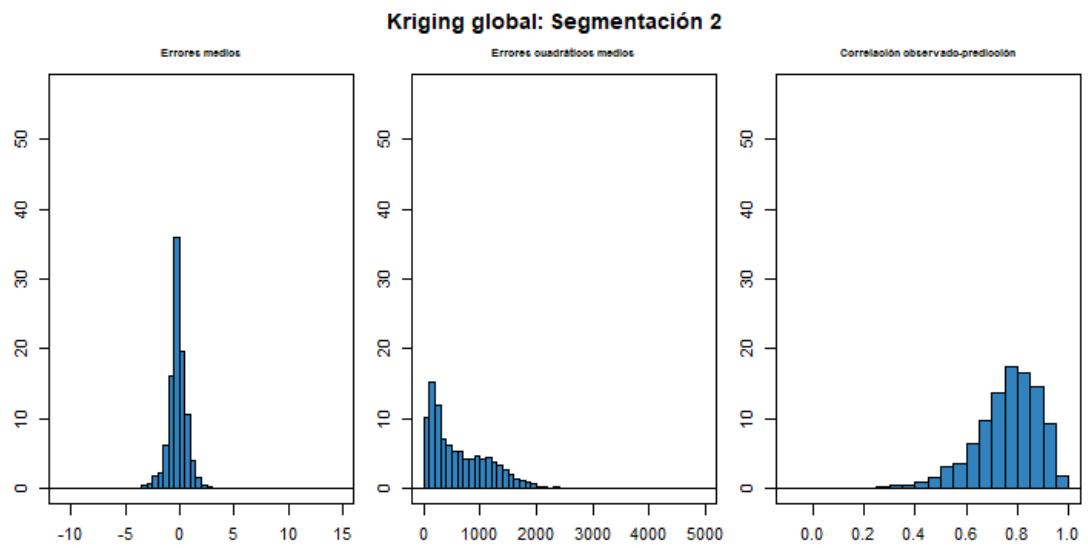


Figura 4.8: Distribución de las medidas de error. Kriging global: Segmentación 2

De nuevo, esta figura se interpreta como la figura 4.6 y la figura 4.7, siendo en esta ocasión la distribución de errores medios más parecida a la del modelo *kriging global*, pero ligeramente peor que ésta.

4.5. Comparación entre modelos

Por último, se va a hacer una comparación entre todos los modelos presentados, para ello se recoge en la siguiente tabla todos los resultados de las medidas de error en el conjunto de test, que se han ido presentando para los diversos modelos.

Tabla 4.9: Media de errores del conjunto de Test para todos los modelos

Modelo	Media de errores		
	Error medio	MSE	Correlación Observado-Predicción
IDW global	0.1246	672.7910	0.7478
IDW estratificado: Zonificación 8 sectores	1.1281	837.4215	0.4717
IDW estratificado: Zonificación 10 sectores	0.6356	999.3133	0.5756
Kriging global	0.0004	643.3256	0.7597
Kriging global por clústers: Segmentación 1	-0.1747	641.1371	0.7595
Kriging global por clústers: Segmentación 2	-0.0927	644.4948	0.7537

Los modelos que tienen una mayor capacidad predictiva son los de kriging, tanto si observamos las correlaciones entre los valores observados y las predicciones, como las otras medidas de error. De entre ellos, el *kriging global* proporciona buenos resultados en cuanto a los errores aunque son los tres similares en cuanto a estas cuestiones, como además se ilustrará más adelante con un ejemplo. Por último, respecto a los modelos de IDW, la estratificación del dominio empeora mucho la capacidad predictiva, aunque se ha simplificado la elección de los parámetros, cabría la posibilidad de obtener mejoras en estos modelos si se entrenasen para cada uno de los estratos. Sin embargo, la delimitación o zonificación del campo visual no parece ser útil en este caso, puesto que los valores puntuales parecen ser independientes del estrato en el que se encuentren y éste no influye en los mismos.

4.5.1. Ejemplo de los modelos

Todos los modelos presentados tienen como objetivo hacer estimaciones de las medidas en otros puntos del campo visual, creando así un mapa más completo. Por ello, se quiere mostrar los resultados de estos mapas a través de una campimetría seleccionada al azar que servirá como ejemplo de aplicación.

Primero se muestra los valores del defecto normalizado en los puntos de medida:

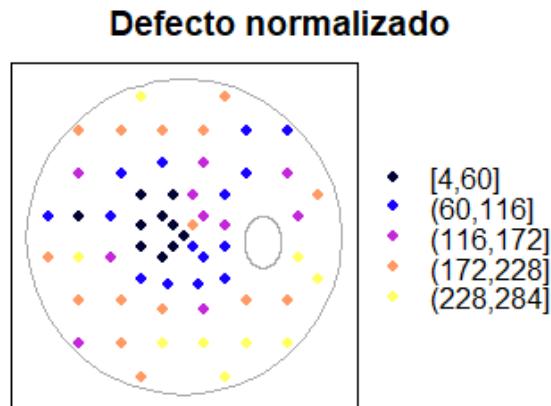


Figura 4.9: Defecto normalizado en la campimetría de ejemplo

Para poder interpolar estos valores a lo largo de toda la superficie, se crea una malla de la resolución que se prefiera, donde cada píxel representará una medición, real o estimada, dependiendo de su posición.

En la siguiente figura se muestran estos mapas campimétricos correspondientes a cada uno de los modelos que se han obtenido.

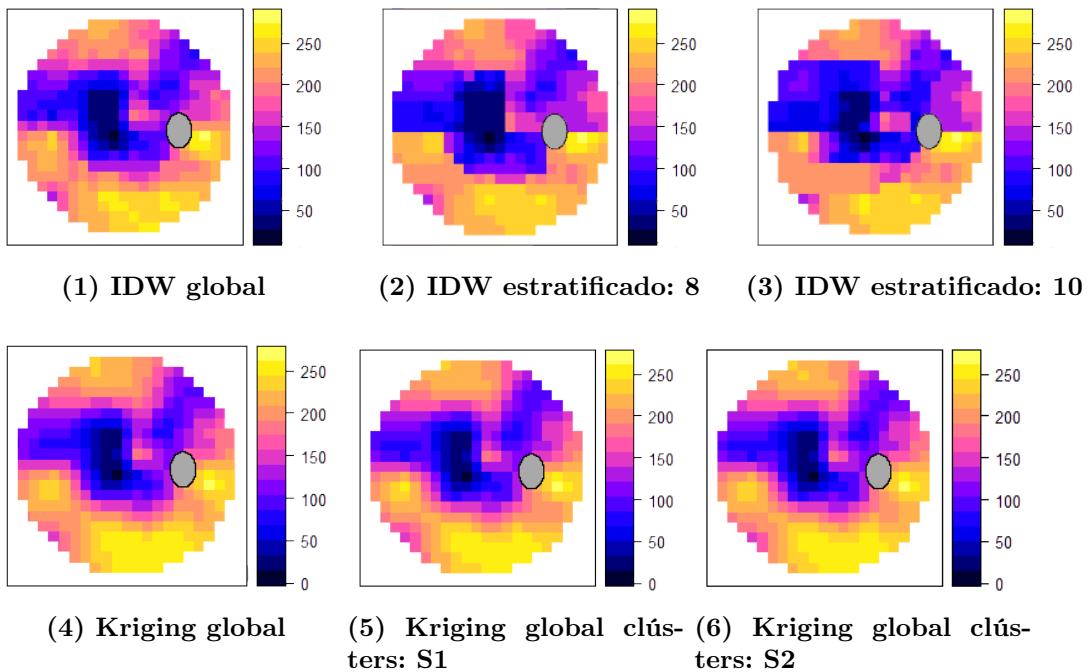


Figura 4.10: Ejemplo de interpolación de la campimetría de ejemplo utilizando los diferentes modelos

Como se observa, los mapas son muy parecidos entre sí, sobretodo observamos estos parecidos entre los modelos que pertenecen a la misma técnica de interpolación, es decir, IDW o kriging. Así, la figura 4.101, la figura 4.102, y la figura 4.103 tienen más parecido entre sí; al igual que entre la figura 4.104, la figura 4.105 y la figura 4.106. También se puede apreciar que estas tres últimas figuras aparentan tener “más definición”; siendo los cambios de color más graduales.

Media de errores				
Modelo	Error medio	MSE	Correlación Observado-Predicción	
IDW global	4.8773	1745.0516		0.8535
IDW estratificado: Zonificación 8 sectores	6.1685	1975.0838		0.4361
IDW estratificado: Zonificación 10 sectores	-3.0364	2625.9872		0.5920
Kriging global	1.1258	1625.7380		0.8631
Kriging global por clústers: Segmentación 1	-0.5625	1501.7269		0.8714
Kriging global por clústers: Segmentación 2	-1.5824	1517.7255		0.8700

Si analizamos los errores medios de esta campimetría en los distintos modelos, también se comprueba que al que en el apartado anterior, los modelos de kriging arrojan mejores resultados. Para este caso en concreto, además, el kriging global no resulta el mejor modelo, si no que esta posición la ocuparía el kriging global por clústers de la segmentación 1, seguido del de la 2.

Capítulo 5

Conclusiones y trabajo futuro

Las campimetrías ópticas constituyen un recurso fundamental utilizado por el personal sanitario y oftalmólogos para el correcto diagnóstico, tratamiento y seguimiento de patologías oculares como el glaucoma u otras enfermedades neurooftalmológicas.

Idealmente, una campimetría recogería la sensibilidad visual del paciente en todo su campo visual, sin embargo, en la práctica, esta información solo está disponible en una serie de puntos muy concretos. Por este motivo, una de las líneas en las que se ha centrado este trabajo, ha sido la de tratar de ampliar esta información puntual en todo el dominio espacial de la campimetría. Esto ha sido posible mediante el ajuste de modelos de interpolación espacial. A lo largo del trabajo se han propuesto diversos modelos con el objetivo de encontrar aquel que ofreciese mejor capacidad predictiva para todas las campimetrías en global. Se ha visto que todos los modelos de kriging presentados proporcionaban mejores resultados, en cuanto a las medidas de error estudiadas, en comparación con los modelos de IDW. También se ha comprobado que estratificar el dominio, según unas áreas delimitadas en las campimetrías comúnmente utilizadas por los expertos en este ámbito, no parece ser una buena estrategia, puesto que se empeora la capacidad predictiva del modelo. Los modelos de kriging ajustados específicamente a grupos con defectos visuales de características similares (kriging global por clústeres) tienen un poder predictivo similar a aquel que hemos denominado como kriging global, y la mejoría de éste frente a los otros dependerá de la campimetría en la que se realice la interpolación. Como trabajo futuro se propone estudiar si el aumento de las campimetrías con las que se calcula el “variograma medio” de los modelos de kriging, mejora la capacidad predictiva de los mismos. Por último, mediante la visualización de un ejemplo al que se le han aplicado estos modelos de interpolación espacial, se ha podido comprobar cómo, efectivamente, se puede extender la información en todo el campo visual de estudio, con la resolución que se desee.

Respecto a la segmentación de pacientes, se han obtenido resultados coherentes con algunos de los defectos visuales más comunes asociados a diversas patologías como el glaucoma u otras enfermedades neurooftalmológicas. Gracias a este tipo de agrupaciones, se facilita el diagnóstico de este tipo de trastornos y, con ello, su correcto tratamiento y seguimiento. En este trabajo, este *clustering* se ha realizado con dos formas de dividir el campo visual y con dos variables distintas: el defecto medio (MD) y la raíz cuadrada de la pérdida de varianza (sLV). Aunque los resultados sean bastante consistentes, se puede plantear ampliar este trabajo siguiendo una metodología similar

pero utilizando muestras de mayor tamaño, otras variables, otros número de clústeres y el uso ambas campimetrías (ojo izquierdo y derecho) con el objetivo de definir mejor los grupos distinguiendo más claramente la patología asociada a la campimetría y recoger aquellas que no se han logrado distinguir, por su escasa representación en el conjunto de datos.

Apéndice A

Campos de los datos

Se adjuntan a continuación una serie de tablas enumerando la información disponible para cada campimetría, así como una descripción para algunas de ellas

Field	Additional information
Name	
Firstname	
Date of birth	MM/dd/YYYY
Gender	Male/Female/Undefined
Ethnicity	
Diagnosis OD	
Diagnosis OS	
Risk factors	
Comment	

Tabla A.1: Campos información paciente. Información extraída de [5]

Field	Additional information
x coordinate	in 1/10°
y coordinate	in 1/10°
Result of test 1	Phase in 1/10 dB if qualitative 1000 absolute defect 1010 relative defect 1020 normal
Result of test 2	Phase in 1/10 dB -1 Not tested
Age matched normal	in 1/10dB

Tabla A.2: Campos resultados prueba en cada punto de la campimetría. Información extraída de [5]

Field	Additional information
Perimeter Model	OCTOPUS
Perimeter Serial Number	
Software Version of Perimeter	
Software Version of Extension	Off, Min, Med, Max, AET (Auto)
Fixation Control Method (Number)	0-4
Software version of Viewer	
Eye	OD/OS/Both eyes/Binocular
Program	
Stimulus size	Goldmann size 1 to 5
Stimulus duration	in ms (100, 200, 500, 1000)
Background	127: 1,27cd/m ² (4asb) - 1000: 10 cd/m ² (31.4asb)
Strategy	0-9
Stimulus color	0-5
Stimulus method	0-5
Examination duration	HH:MM:SS
Examination date	MM/dd/YYYY
Examination time	HH:MM:SS
Stage	
Test locations	
Questions	
Repetitions	
Positive catch trials	
False positive answers	
Negative catch trials	
False negative answers	
Notes	
Sphere	
Cylinder	
Axis	
Visual acuity	
Pupil size	
IOP	

Tabla A.3: Campos información prueba. Información extraída de [5]

Apéndice B

Medidas de error en el modelo de kriging global por clústers

B.1. Segmentación 1

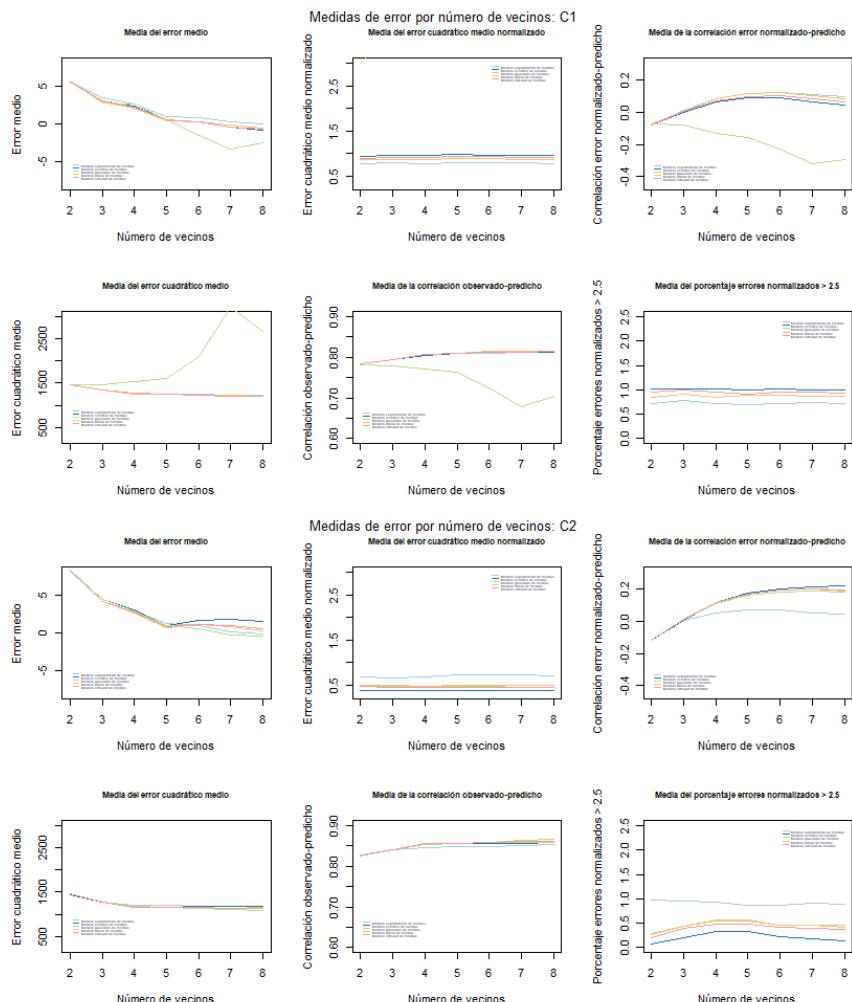


Figura B.1: Evolución de las medidas de error por número de vecinos. Segmentación 1 (i)

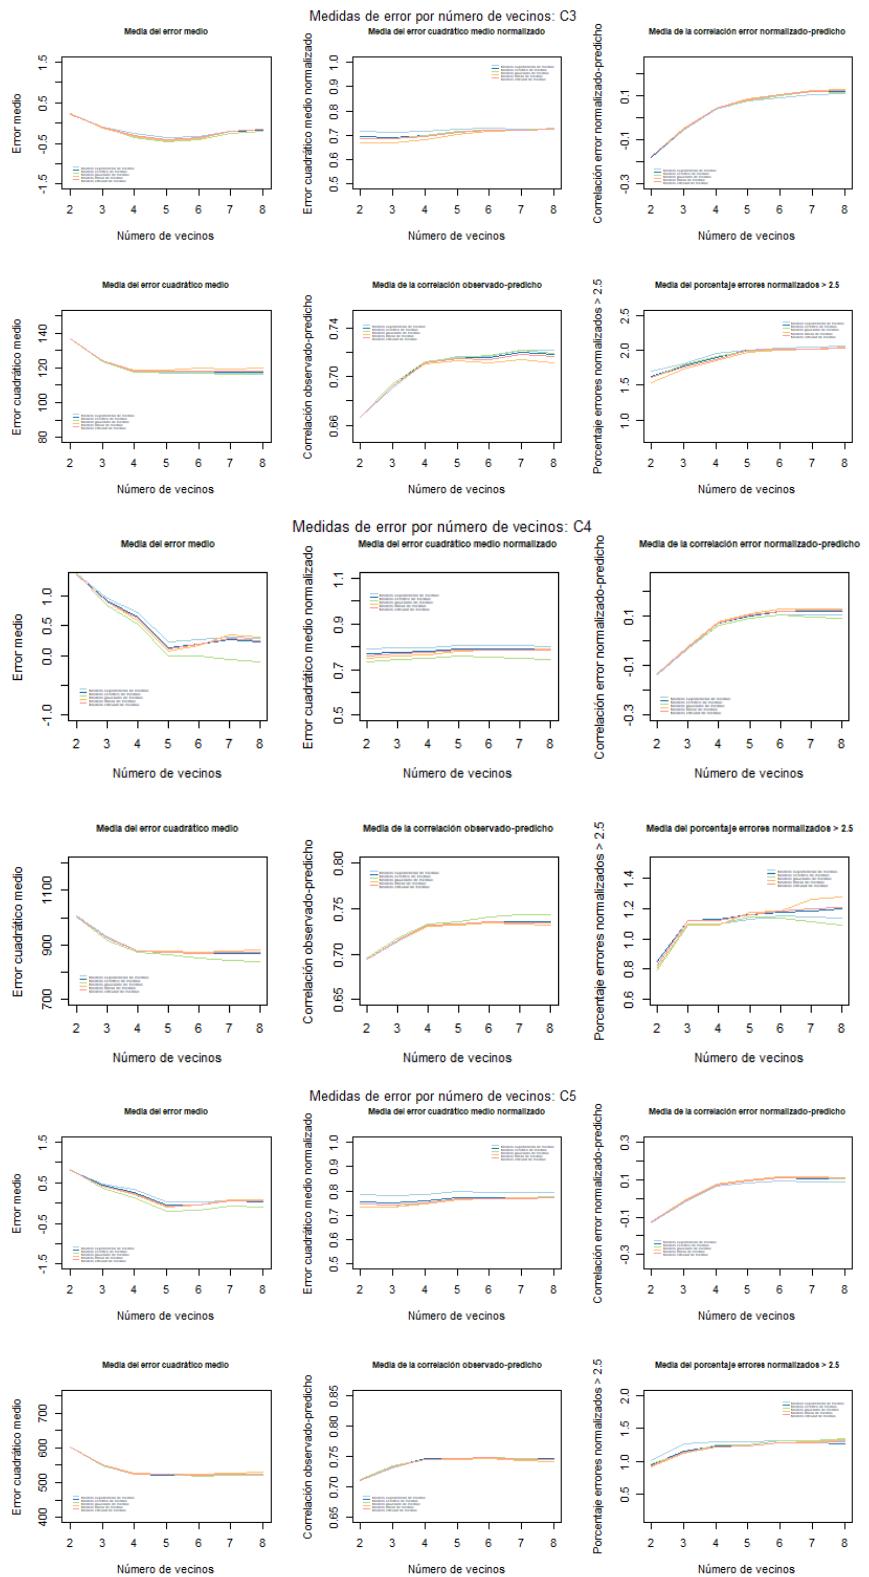


Figura B.2: Evolución de las medidas de error por número de vecinos. Segmentación 1 (ii)

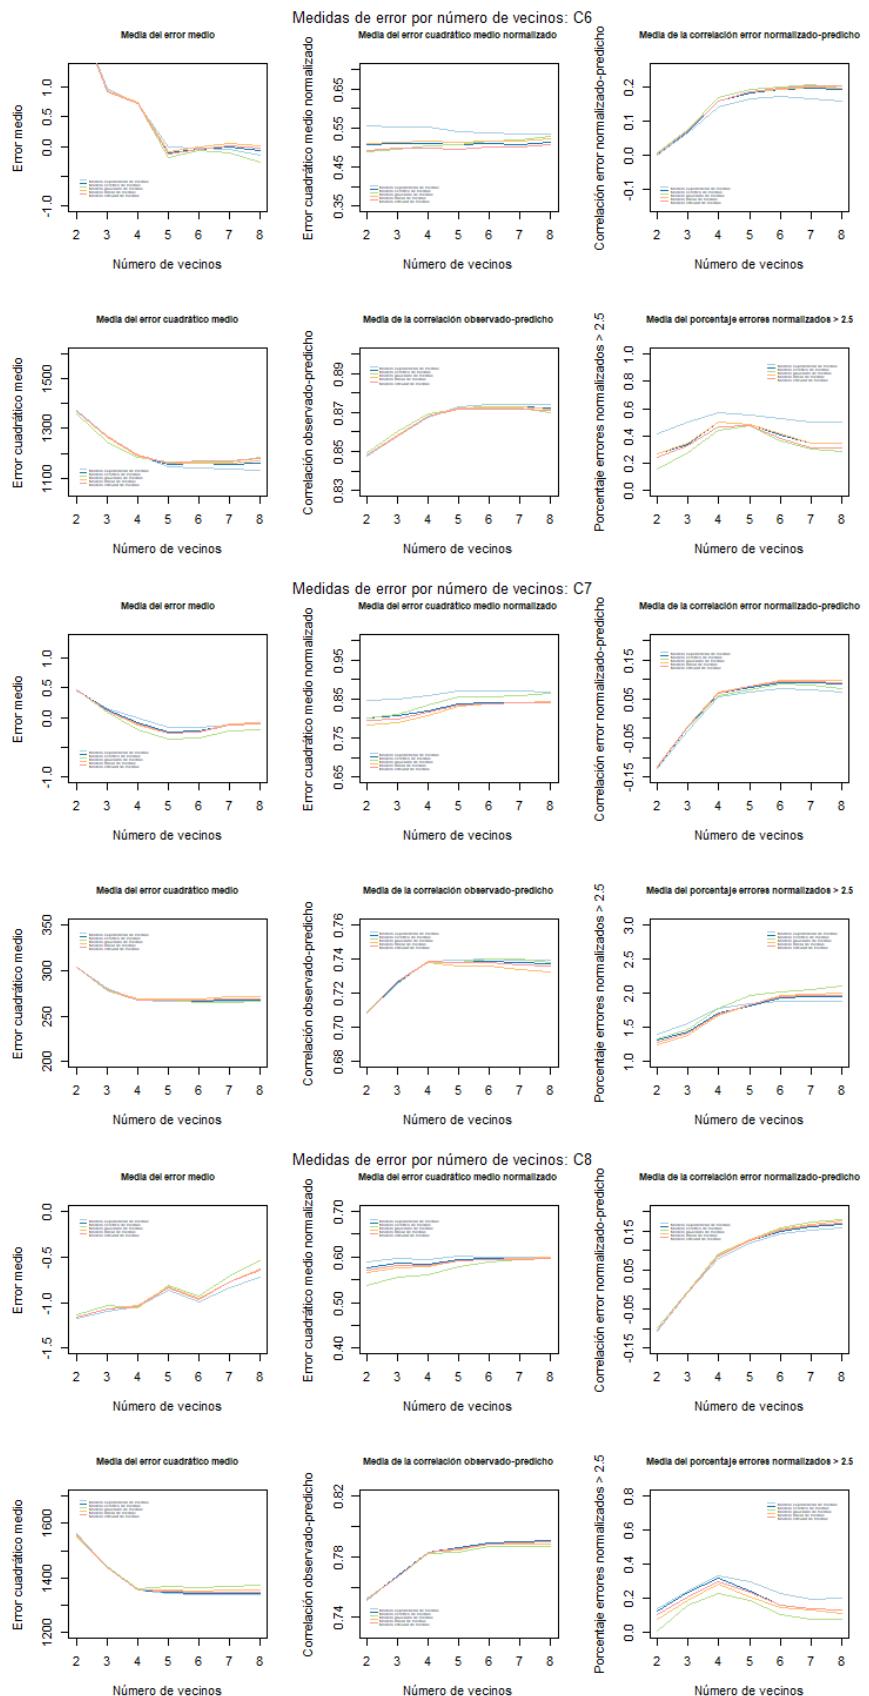


Figura B.3: Evolución de las medidas de error por número de vecinos. Segmentación 1 (iii)

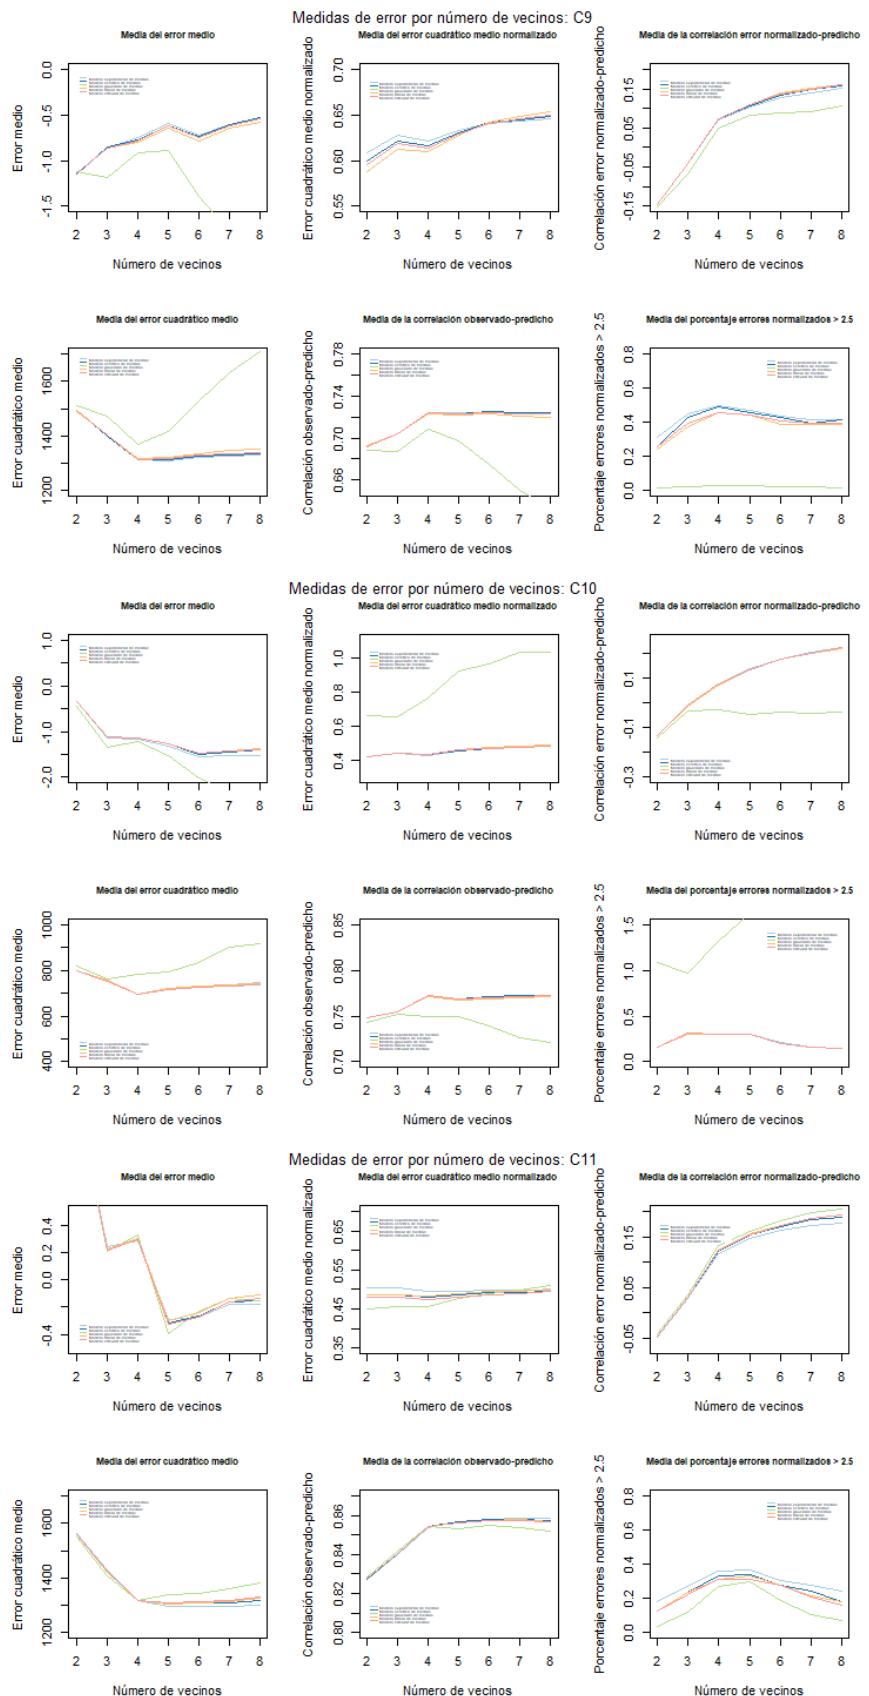


Figura B.4: Evolución de las medidas de error por número de vecinos. Segmentación 1 (iv)

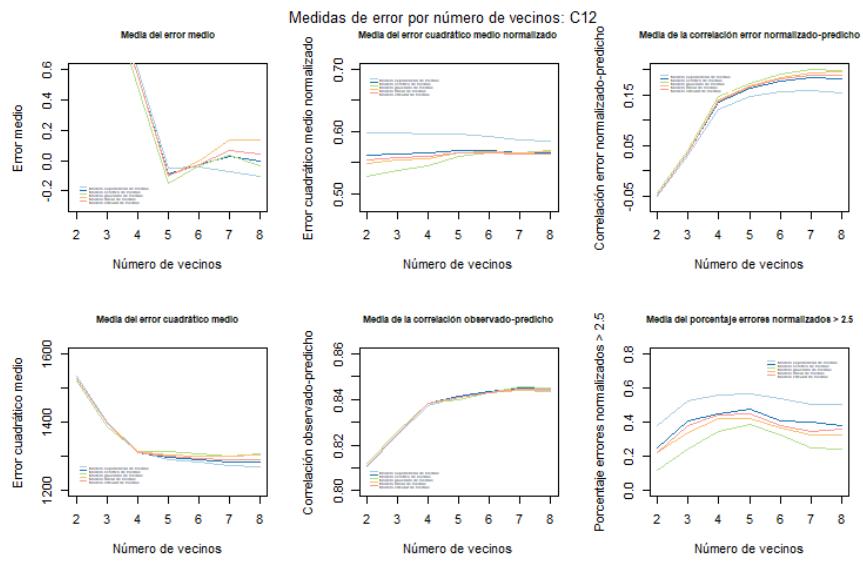


Figura B.5: Evolución de las medidas de error por número de vecinos. Segmentación 1 (v)

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	0.8338	0.3266	1.4784	0.3493	0.3313
Error cuadrático medio	1239.8424	1228.38	2094.1841	1221.9376	1223.2136
Error cuadrático medio normalizado	0.7873	0.962	26.6941	0.8772	0.9221
Correlación observado-predicho	0.8111	0.8114	0.7255	0.8138	0.8127
Correlación predicho-erroneo normalizado	0.1173	0.085	-0.2312	0.1179	0.1179
Porcentaje errores normalizados < 2.5	0.7234	1.0128	11.1065	0.8886	0.9430

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.0541	1.5586	0.4069	0.309	0.5075
Error cuadrático medio	119.553211	117.232311	108.8565	114.46494	113.4928
Error cuadrático medio normalizado	0.7103	0.3811	0.4431	0.4836	0.4434
Correlación observado-predicho	0.8526	0.8579	0.8657	0.8592	0.8606
Correlación predicho-observado	0.0413	0.2163	0.1801	0.1849	0.1932
Porcentaje errores normalizados > 2.5	0.8951	0.1428	0.4475	0.419	0.3609

(1) C1

(2) C2

	Exponencial	Esférico	Gaussiano	Lineal	Circular
Error medio	-0.0939	-0.1057	-0.1038	-0.1226	-0.1109
Error cuadrático medio	124.4355	123.98	123.4263	123.9735	123.9597
Error cuadrático medio normalizado	0.7116	0.6906	0.6868	0.6702	0.6842
Correlación observado-predicho	0.6909	0.6942	0.6943	0.6925	0.6925
Correlación predicho-error normalizado	-0.0571	-0.0523	-0.0499	-0.0493	-0.0513
Porcentaje errores normados > 2.5	1.8018	1.7797	1.7962	1.7299	1.7668

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	0.2294	0.1282	-0.0105	0.0826	0.1135
Error cuadrático medio	872.0446	872.1796	863.6578	877.4218	873.5243
Error cuadrático medio normalizado	0.8065	0.7906	0.7595	0.7800	0.7684
Correlación observado-predicto	0.7334	0.7355	0.7358	0.7322	0.7332
Correlación predictivo-error normalizado	0.0897	0.1001	0.0892	0.1064	0.1024
Porcentaje errores normales > 2.5	1.1308	1.1582	1.1458	1.1757	1.1607

(3) C3

(4) C4

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	0.3358	0.2551	0.1277	0.2194	0.243
Error cuadrático medio	524.8258	524.6764	525.0331	526.0054	525.0957
Error cuadrático medio normalizado	0.7854	0.7596	0.7496	0.7457	0.7522
Correlación observado-predicho	0.7462	0.7461	0.7455	0.7453	0.7458
Correlación predicho-error normalizado	0.0631	0.0705	0.0733	0.0741	0.0748
Porcentaje errores normalizados > 2.5	1.2999	1.2307	1.2471	1.2198	1.2234

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-.0509	-0.124	-0.1059	0.0491	0.0137
Error cuadrático medio	1134.2556	1155.9179	1165.0686	1158.4353	1169.2066
Error cuadrático medio normalizado	0.5347	0.5088	0.5195	0.5172	0.5024
Correlación observado-predicho	0.8744	0.873	0.8723	0.8729	0.8718
Correlación predicho-observado	0.1659	0.195	0.2048	0.1981	0.2018
Porcentaje errores normalizados > 2.5	0.4996	0.3479	0.3033	0.3479	0.3122

(5) C5

(6) C6

Figura B.6: Medidas de error por modelos, fijado n. Segmentación 1 (i)

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.0052	-0.0883	-0.1965	-0.116	-0.0978
Error cuadrático medio	267.2555	267.5482	267.8978	268.3446	267.7729
Error cuadrático medio normalizado	0.8574	0.8209	0.8355	0.8083	0.8103
Correlación observado-predicho	0.7389	0.7388	0.7383	0.738	0.7386
Correlación predicho-eror normalizado	0.0555	0.0636	0.0593	0.0665	0.0647
Porcentaje errores normalizados > 2.5	1.7748	1.7103	1.784	1.6703	1.6991

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-.72729	-.644	-.5352	-.627	-.6413
Error cuadrático medio	1337.3069	1341.6891	1372.1367	1358.0191	1347.5202
Error cuadrático medio normalizado	0.5986	0.595	0.5974	0.5993	0.596
Correlación observado-predicho	0.7902	0.7905	0.7871	0.7885	0.7898
Correlación predicho-erro normalizada	0.1572	0.1675	0.1794	0.1751	0.1703
Porcentaje errores normalizados > 2.5	0.202	0.1317	0.079	0.1142	0.1317

(1) C7

(2) C8

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.7502	-0.7748	-0.9214	-0.7994	-0.78
Error cuadrático medio	1311.6182	1312.3108	1370.5986	1315.5582	1313.2957
Error cuadrático medio normalizado	0.6214	0.6165	0.319	0.6096	0.6199
Correlación observado-predicho	0.7239	0.7239	0.709	0.7233	0.7237
Correlación predicho-erro normalizada	0.0993	0.0724	0.0499	0.0745	0.0734
Porcentaje errores normalizados >2.5	0.4953	0.4876	0.031	0.4566	0.4566

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-1.1739	-1.1489	-1.2154	-1.1376	-1.1447
Error cuadrático medio	696.6616	696.0353	781.1868	697.6945	698.3789
Error cuadrático medio normalizado	0.428	0.4307	0.7634	0.4298	0.4307
Correlación observado-predicho	0.7722	0.7724	0.75	0.7718	0.7723
Correlación predicho-erro normalizado	0.0741	0.0738	-0.0269	0.0722	0.0734
Porcentaje errores normalizados > 2.5	0.3039	0.3039	3.235	0.3039	0.3039

(3) C9

(4) C10

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.181	-0.1539	-0.1539	-0.1076	-0.1376
Error cuadrático medio normalizado	1301.1213	1317.8755	1382.5881	1325.7913	1328.2286
Error cuadrático medio normalizado	0.4992	0.4961	0.5019	0.5015	0.4939
Correlación observado-predicho	0.8585	0.8575	0.8519	0.8569	0.8567
Correlación predicho-erro normalizado	0.1763	0.1893	0.2052	0.1932	0.194
Porcentaje errores normalizados > 2.5	0.2421	0.1794	0.0717	0.1794	0.1614

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.108	-0.0028	-0.0376	0.1338	0.0396
Error cuadrático medio	1270.8043	1284.1027	1306.3748	1304.161	1291.9134
Error cuadrático medio normalizado	0.5855	0.5653	0.5689	0.5683	0.5630
Correlación observado-predicho	0.8443	0.8451	0.845	0.8437	0.8445
Correlación predicho-error normalizado	0.153	0.1825	0.1977	0.1948	0.1877
Porcentaje errores normalizados > 2.5	0.5053	0.379	0.2421	0.3264	0.3579

(5) C11

(6) C12

Figura B.7: Medidas de error por modelos, fijado n. Segmentación 1 (ii)

B.2. Segmentación 2

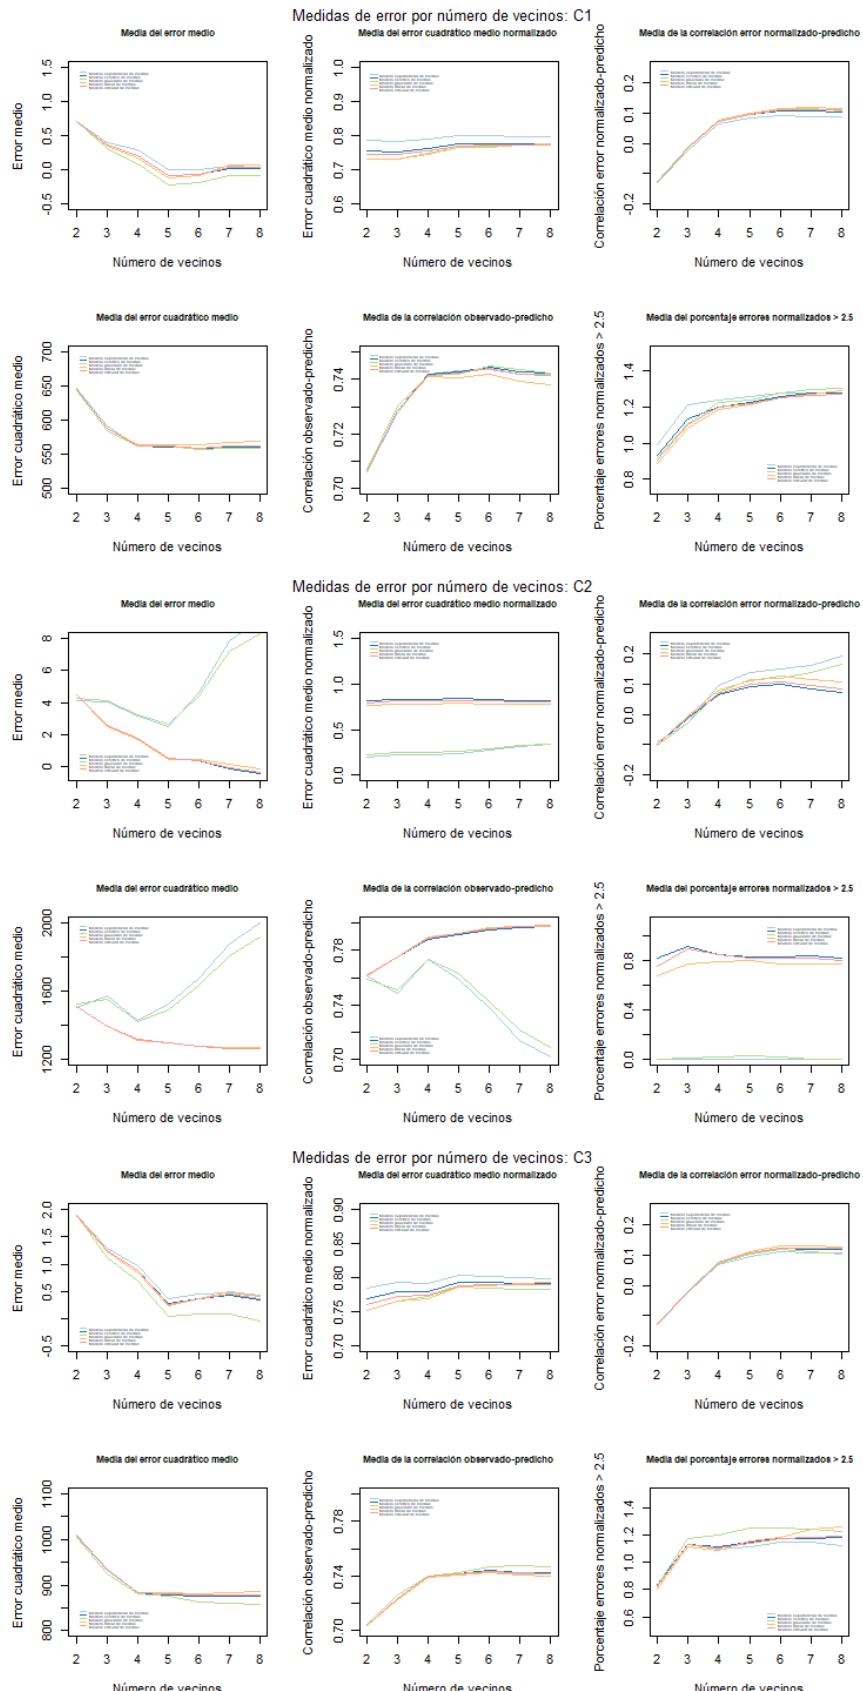


Figura B.8: Evolución de las medidas de error por número de vecinos. Segmentación 2 (i)

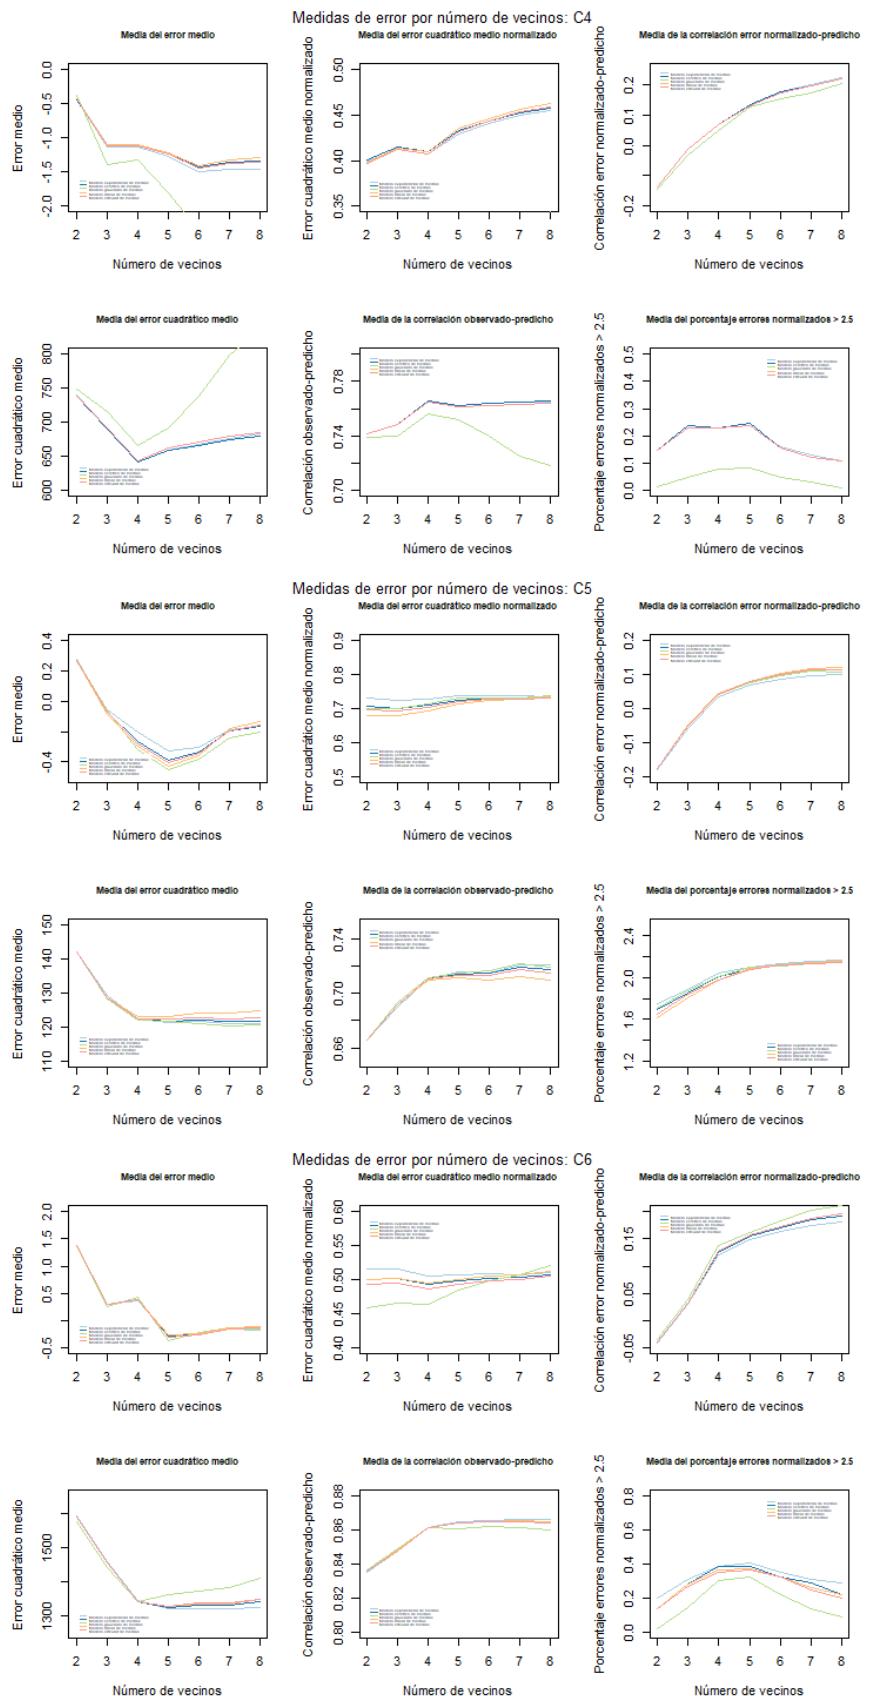


Figura B.9: Evolución de las medidas de error por número de vecinos. Segmentación 2 (ii)

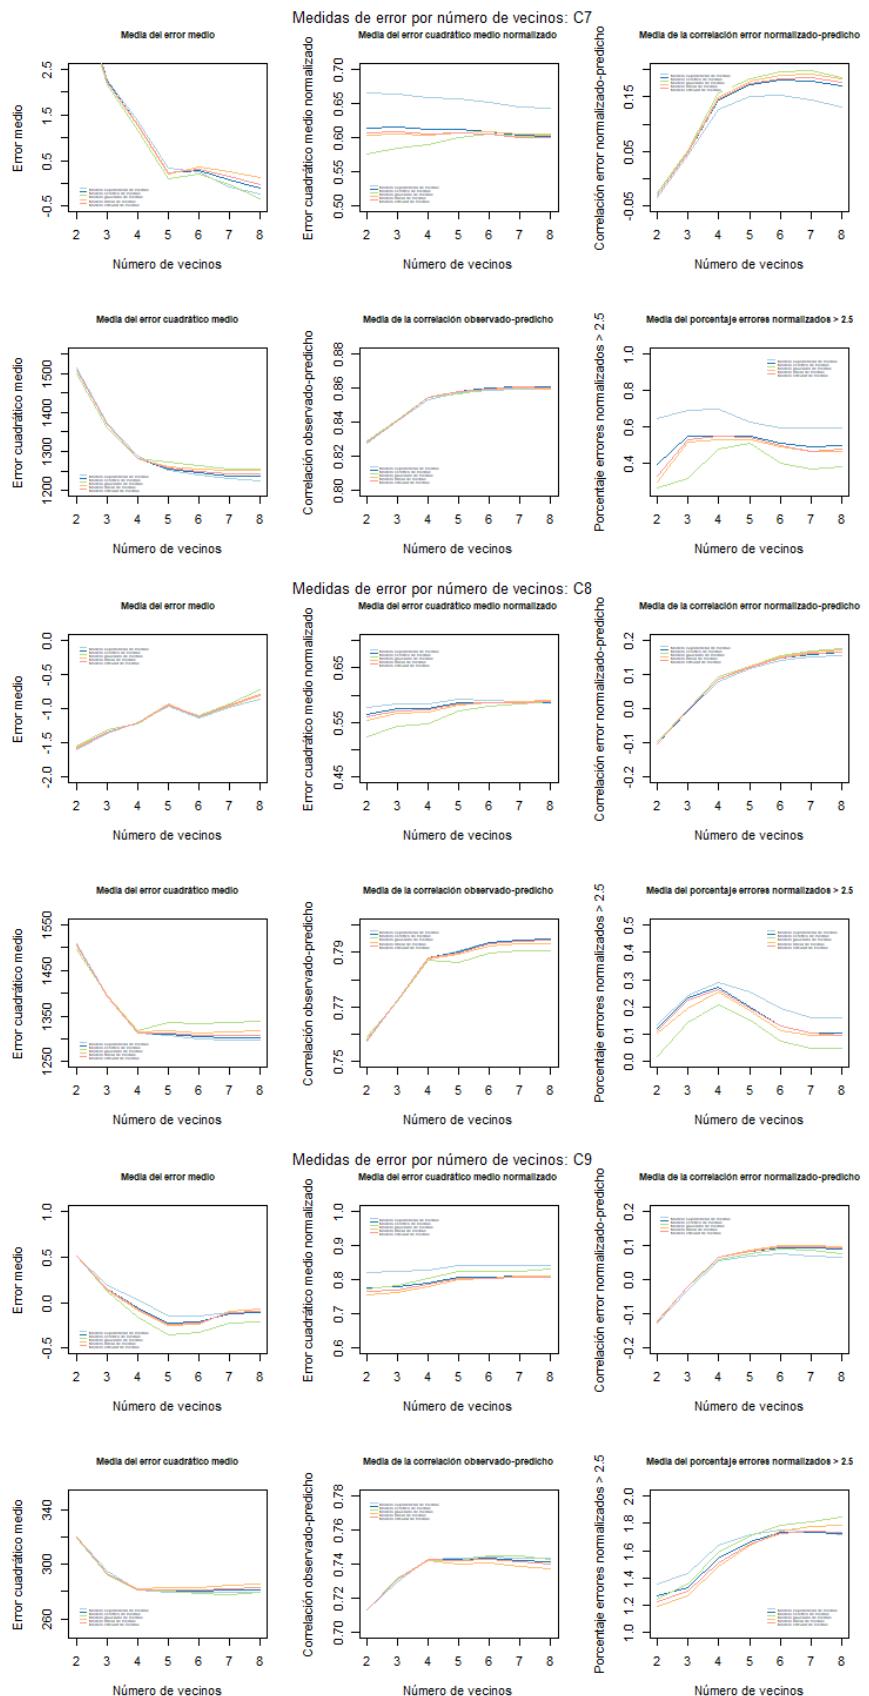


Figura B.10: Evolución de las medidas de error por número de vecinos. Segmentación 2 (iii)

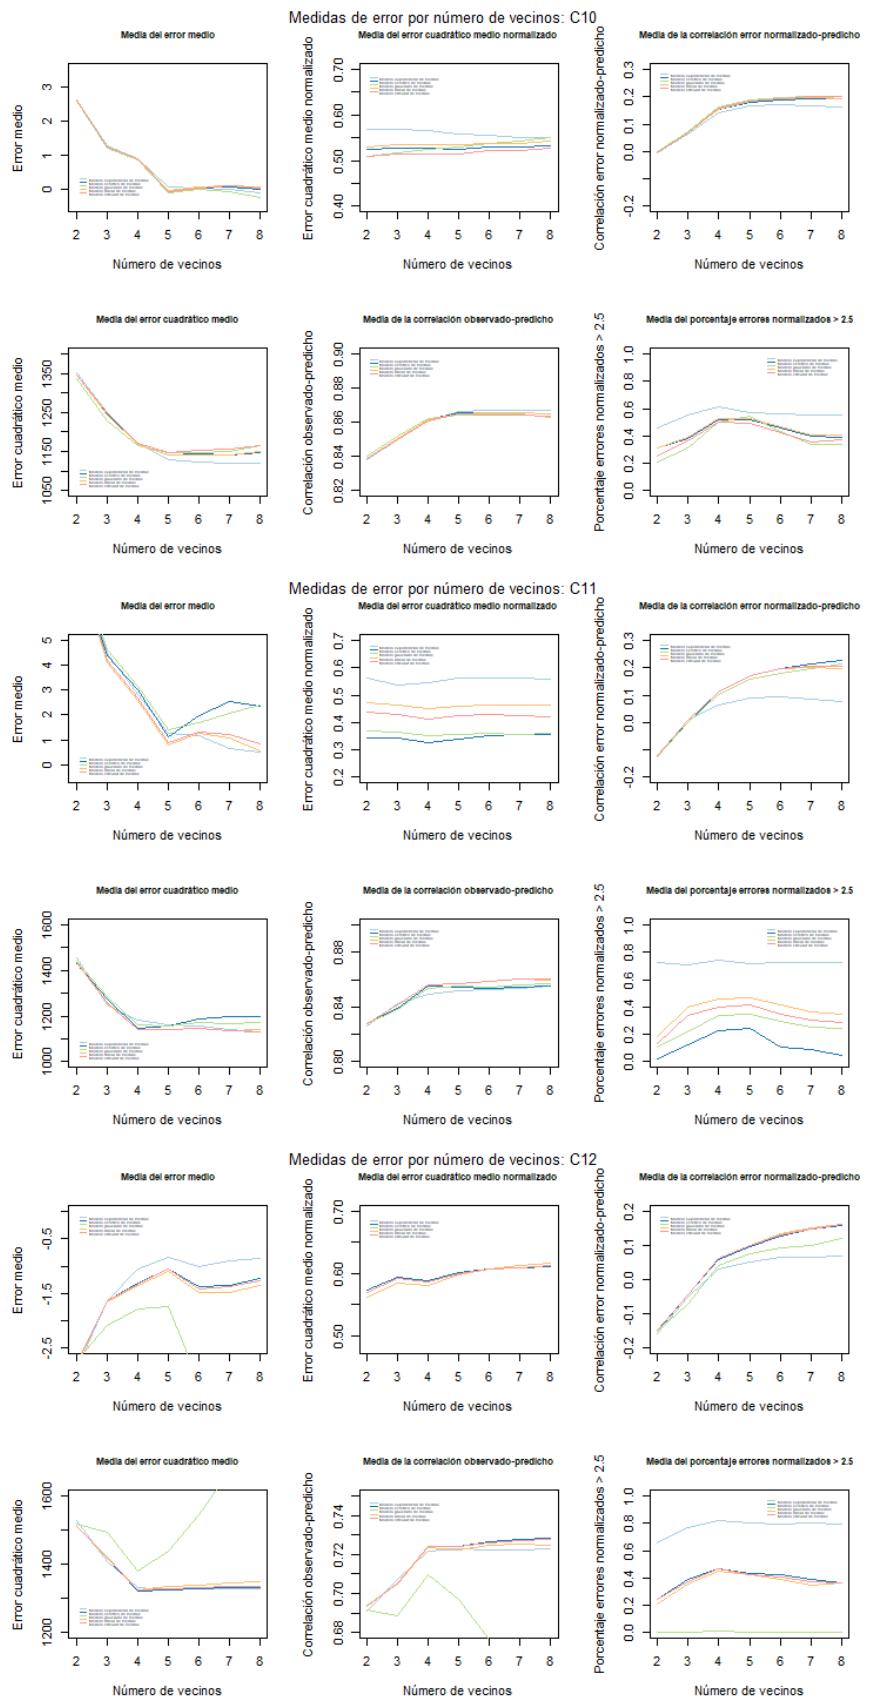


Figura B.11: Evolución de las medidas de error por número de vecinos.
Segmentación 2 (iv)

	Exponencial	Esférico	Gausiano	Lineal	Circular		Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	0.0089	-0.0594	-0.1822	-0.0795	-0.0666	Error medio	9.2146	-0.3849	8.2628	-0.0819	-0.3246
Error cuadrático medio	559.4133	558.3035	557.4105	563.6306	559.7878	Error cuadrático medio	1999.3082	1260.4962	1918.0923	1271.6865	1260.4643
Error cuadrático medio normalizado	0.7989	0.7756	0.769	0.7678	0.7713	Error cuadrático medio normalizado	0.3365	0.8178	0.3424	0.7743	0.7993
Correlación observado-predicho	0.7436	0.7444	0.7449	0.742	0.7438	Correlación observado-predicho	0.7017	0.7974	0.7089	0.7974	0.798
Correlación predicho-error normalizado	0.0925	0.1083	0.1146	0.1164	0.1117	Correlación predicho-error normalizado	0.1926	0.0725	0.1652	0.1074	0.0839
Porcentaje errores normalizados >2.5	1.2735	1.2532	1.2772	1.2514	1.2514	Porcentaje errores normalizados >2.5	0	0.8203	0	0.7661	0.8

(1) C1

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	0.3747	0.2778	0.0382	0.2335	0.2655
Error cuadrático medio	878.0368	878.4383	874.6925	882.7863	879.8478
Error cuadrático medio normalizado	0.8032	0.7932	0.787	0.7859	0.789
Correlación observado-predicho	0.7415	0.7415	0.7421	0.7403	0.7411
Correlación predicho-error normalizado	0.0967	0.1047	0.1019	0.1108	0.1072
Porcentaje errores normalizados >2.5	1.115	1.1458	1.2551	1.1598	1.1402

(3) C3

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.1876	-0.1958	-0.2397	-0.1779	-0.1933
Error cuadrático medio	121.0926	121.7471	120.4453	124.2768	122.4229
Error cuadrático medio normalizado	0.7373	0.73	0.7321	0.7294	0.7293
Correlación observado-predicho	0.7204	0.7188	0.7213	0.7125	0.7171
Correlación predicho-error normalizado	0.0986	0.1111	0.1099	0.1185	0.1138
Porcentaje errores normalizados >2.5	2.153	2.1343	2.1309	2.1377	2.136

(5) C5

(2) C2

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-1.1373	-1.1135	-1.3169	-1.1005	-1.1179
Error cuadrático medio	642.4838	641.867	666.2953	643.1822	643.2706
Error cuadrático medio normalizado	0.4072	0.4098	0.2565	0.4093	0.407
Correlación observado-predicho	0.7651	0.7653	0.7558	0.7648	0.7648
Correlación predicho-error normalizado	0.0699	0.0694	0.0479	0.0675	0.068
Porcentaje errores normalizados >2.5	0.2311	0.2311	0.077	0.2311	0.2311

(4) C4

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.1707	-0.1488	-0.1545	-0.11	-0.133
Error cuadrático medio	1324.4979	1339.6024	1408.2894	1346.2854	1348.8549
Error cuadrático medio normalizado	0.5104	0.5076	0.5202	0.5126	0.5054
Correlación observado-predicho	0.866	0.8652	0.8599	0.8647	0.8645
Correlación predicho-error normalizado	0.1799	0.1915	0.2101	0.1949	0.1957
Porcentaje errores normalizados >2.5	0.2929	0.2197	0.0942	0.2197	0.1988

(6) C6

Figura B.12: Medidas de error por modelos, fijado n. Segmentación 2 (i)

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.2355	-0.0945	-0.3422	0.1278	-0.0248
Error cuadrático medio	1226.2887	1235.3566	1256.3083	1253.0681	1242.1743
Error cuadrático medio normalizado	0.6428	0.6024	0.6045	0.6055	0.5996
Correlación observado-predicho	0.8597	0.8606	0.86	0.8695	0.8602
Correlación predicho-error normalizado	0.1307	0.1693	0.1861	0.1835	0.1755
Porcentaje errores normalizados >2.5	0.5932	0.4979	0.3814	0.4661	0.4767

(1) C7

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.8564	-0.7958	-0.7218	-0.8094	-0.795
Error cuadrático medio	1297.8476	1303.0758	1338.7485	1317.0855	1307.0715
Error cuadrático medio normalizado	0.5891	0.587	0.5893	0.5899	0.5874
Correlación observado-predicho	0.7949	0.7948	0.7905	0.7932	0.7943
Correlación predicho-error normalizado	0.1568	0.1656	0.1769	0.1728	0.1675
Porcentaje errores normalizados >2.5	0.1607	0.1044	0.0482	0.0964	0.0964

(2) C8

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	0.0312	-0.0553	-0.1654	-0.0848	-0.066
Error cuadrático medio	281.0443	281.2301	281.5147	282.0638	281.485
Error cuadrático medio normalizado	0.8297	0.7918	0.8052	0.7789	0.7852
Correlación observado-predicho	0.7429	0.7428	0.7424	0.742	0.7426
Correlación predicho-error normalizado	0.0557	0.0645	0.0605	0.0674	0.0659
Porcentaje errores normalizados >2.5	1.6354	1.5408	1.5866	1.4829	1.5134

(3) C9

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.1133	-0.0192	-0.2648	0.062	0.0415
Error cuadrático medio	119.343	1148.6243	1163.8105	1150.6913	1164.0445
Error cuadrático medio normalizado	0.5516	0.5322	0.5517	0.5434	0.5274
Correlación observado-predicho	0.8669	0.8648	0.863	0.8647	0.8634
Correlación predicho-error normalizado	0.1611	0.1926	0.1924	0.1944	0.2009
Porcentaje errores normalizados >2.5	0.5571	0.3923	0.3374	0.408	0.3688

(4) C10

	Exponencial	Esférico	Gausiano	Lineal	Circular
Error medio	-0.8422	-1.0453	-1.7357	-1.0884	-1.0561
Error cuadrático medio	1325.6161	1325.1132	1437.8317	1333.9657	1327.146
Error cuadrático medio normalizado	0.7267	0.6015	0.3309	0.5979	0.6004
Correlación observado-predicho	0.7228	0.7243	0.6968	0.7223	0.7239
Correlación predicho-error normalizado	0.0534	0.0987	0.0781	0.1003	0.0994
Porcentaje errores normalizados >2.5	0.8025	0.435	0	0.4275	0.4275

(5) C11

(6) C12

Figura B.13: Medidas de error por modelos, fijado n. Segmentación 2 (ii)

Bibliografía

- [1] R. Bivand, E. J. Pebesma, and V. Gómez-Rubio. *Applied spatial data analysis with R*, chapter 8, pages 191–235. Use R! Springer, New York, 6 edition, 2008.
- [2] J. Flammer. The concept of visual field indices. *Graefe's Archive for Clinical and Experimental Ophthalmology*, 224(5):389–392, 1986.
- [3] V. for Life. What is visual field loss. <https://visionforlifeworks.com/blog/2018/02/05/visual-field-loss>. Accessed: 2021-01-01.
- [4] F. C. Glen, N. D. Smith, and D. P. Crabb. Impact of superior and inferior visual field loss on hazard detection in a computer-based driving test. *British Journal of Ophthalmology*, 99(5):613–617, 2015.
- [5] Haag-Streit AG, Köniz, Switzerland. *Application Note “Column Description for EyeSuite Perimetry Statistical Export”*, 2016.
- [6] T. Hastie, R. Tibshirani, and J. Friedman. *The Elements of Statistical Learning*. Springer Series in Statistics. Springer New York Inc., New York, NY, USA, 2001.
- [7] T. Hastie, R. Tibshirani, and J. Friedman. *An Introduction to Statistical Learning with Applications in R*, chapter Unsupervised Learning. Springer New York Inc., New York, NY, USA, 2001.
- [8] M. J. Hogan, J. A. Alvarado, and J. E. Weddell. *Histology of the human eye; an atlas and textbook*. Saunders, Philadelphia, 1971.
- [9] I. T. . R. C. (ITRC). Geospatial analysis for optimization at environmental sites. <http://itrcweb.org/Team/Public?teamID=62.>, Washington D.C, 2016.
- [10] A. Kassambara. *Practical Guide to Cluster Analysis in R: Unsupervised Machine Learning*, volume 1. STHDA, 2017.
- [11] J. L. Keltnner, C. A. Johnson, K. E. Cello, Edwards, S. E. M. A., Bandermann, M. A. Kass, and M. O. Gordon. Classification of visual field abnormalities in the ocular hypertension treatment study. *Archives of ophthalmology*, 121(5):643–650, 1960.
- [12] N. Lam. Spatial interpolation methods: a review. *American Cartographer*, 10:129–149, January 1983.
- [13] A. Lorenzo. *Análisis de Campimetrias Visuales mediante Estadística Espacial*. PhD thesis, Máster TECI, 2019.

- [14] S. Mandava, M. Zulauf, T. Zeyen, and J. Caprioli. An evaluation of clusters in the glaucomatous visual field. *American Journal of Ophthalmology*, 116(6):684 – 691, 1993.
- [15] D. Myers. On variogram estimation. In A. Ozturk and E. C. Van Der Meulen, editors, *Proceedings of the Icosco-I Conference, the First International Conference on Statistical Computing, Cesme, Turkey, March-April 1987*, pages 261–281. American Sciences Press, sep 1991.
- [16] E. J. Pebesma. Multivariable geostatistics in s: the gstat package. *Computers & Geosciences*, 30(7):683 – 691, 2004.
- [17] L. Racette, M. Fischer, H. Bebie, G. Holló, C. A. Johnson, and C. Matsumoto. *Visual Field Digest. A guide to perimetry and the Octopus perimeter*. Haag-Streit AG, Köniz, Switzerland, 6 edition, 7 2016. Illustrated by Philip Earnhart.